

申请上海交通大学硕士学位论文

SQL 查询语句的自动生成技术研究

论文作者 熊 云 翔

学 号 116037910048

导 师 沈备军 副教授

专 业 软件工程

答辩日期 2019 年 1 月 9 日

Submitted in total fulfillment of the requirements for the degree of Master
in Software Engineering

Research on Automatic Generation Technology of SQL Query Statement

YUNXIANG XIONG

Advisor

Prof. BEIJUN SHEN

DEPART OF SOFTWARE ENGINEERING, SCHOOL OF ELECTRONIC INFORMATION AND ELECTRICAL
ENGINEERING

SHANGHAI JIAO TONG UNIVERSITY

SHANGHAI, P.R.CHINA

Jan. 9th, 2018

上海交通大学 学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：_____

日 期：_____年 ____月 ____日

上海交通大学 学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权上海交通大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于

保 密 ☐，在 _____ 年解密后适用本授权书。

不保密 ☐。

(请在以上方框内打 ☒)

学位论文作者签名： _____

指导教师签名： _____

日 期： _____ 年 ____ 月 ____ 日

日 期： _____ 年 ____ 月 ____ 日

SQL 查询语句的自动生成技术研究

摘要

随着 IT 和互联网技术地不断发展, 医疗、教育、金融等各个行业都在使用关系型数据库作为数据存储。技术人员在软件开发过程中会频繁地使用 SQL 语句用于数据的增删改查, 业务人员也经常使用 SQL 语句进行报表与在线分析 (OLAP) 的定制, 从数据库中获取所需信息。但是, SQL 语言本质上是一种编程语言。使用者首先需要具有一定的数据库和 SQL 语言相关专业知识, 并且需要在熟悉数据库模式的前提下, 才能熟练的进行数据库的管理。如何降低 SQL 语言的学习成本、如何更快更好地生成 SQL 查询语句、如何使用更自然的方式生成 SQL 语言等问题一直都是学术界和工业界想要解决的问题。

为了解决上述问题, 本文对 SQL 查询语句的自动生成技术进行研究, 分析了该领域的现有研究成果, 从交互式自然语言接口生成 SQL 查询语句和自然语言生成 SQL 查询语句两种方式展开研究。

本文主要的贡献和创新点包括:

1) 研究提出了一种基于映射的 INL2SQL 生成方法。该方法使用依赖解析树生成、解析树节点映射、解析树优化重构、查询树翻译模块对用户输入的查询进行意图的解析并将其映射到 SQL 查询语句上。同时, 通过交互式对话器和用户接口模块对意图解析和映射进行补充和重构, 解决意图缺失和歧义问题。

2) 研究提出了一种基于深度强化学习的 NL2SQL 生成方法。本文提出将系统分为离线训练阶段和在线生成阶段, 使用强化学习将 SQL 语句的执行结果用于神经网络模型的强化。提出了由编码器和解码器构成的神经网络模型结构。将网络模型的学习目标转换为策略的优化问题并给出了模型的状态和动作的定义。提出了解决 SQL 查询语句中的过滤条件的顺序问题、隐式列名问题的解决方法。

3) 研究提出了一种基于多任务学习的 NL2SQL 生成方法。该方法通过设计 TCR 模板, 将中文自然语言转换为英文自然语言任务和英文自然语言转换为 SQL 查询语句任务进行统一。提出由编码器和解码器构成的多任务网络模型, 通过单独编码、对准、对偶协同注意力、压缩、自注意力和最终编码阶段进行编码, 通过结果表示、自注意力、获得中间状态、任务与内容注意力、获得任务与内容状态、多指针生成阶段进行解码, 并运用不同的优化策略进行多任务的学习。

本文在多个数据集上进行了实验。实验结果证明，基于映射的 INL2SQL 生成方法减少了自然语言解析中出现的歧义问题和错误情况，提升了准确性。基于深度强化学习的 NL2SQL 生成方法在 WikiSQL 数据集上的表现一流，在 Spider 数据集的验证集和测试集上的表现超过同类方法，达到 23.2% 和 24.1%。基于多任务学习的 NL2SQL 生成方法在 WikiSQL 数据集上达到 72.4% 和 80.4% 的最高水平，证明了方法的有效性和准确性。在引入更多的任务进行学习时，该方法达到了 571.7 的总分，证明了该方法能够有效解决中文自然语言生成 SQL 查询语句问题，同时还具有很好的通用性和可拓展性。

关键词：SQL 生成，交互式自然语言接口，NL2SQL，多任务学习

RESEARCH ON AUTOMATIC GENERATION TECHNOLOGY OF SQL QUERY STATEMENT

ABSTRACT

write **KEY WORDS:** SJTU, master thesis, XeTeX/LaTeX template

目 录

插图索引	X
表格索引	XI
算法索引	XIII
第一章 绪论	1
1.1 研究背景	1
1.1.1 交互式自然语言接口生成 SQL 查询语句	1
1.1.2 自然语言自动生成 SQL 查询语句	2
1.2 研究目标和研究内容	3
1.3 论文结构	4
第二章 基于映射的 INL2SQL 生成	5
2.1 研究问题	5
2.2 相关工作	6
2.3 解决方案	7
2.3.1 依赖解析树生成	10
2.3.2 解析树节点映射	10
2.3.3 解析树优化重构	11
2.3.4 查询树翻译	14
2.4 实验与分析	15
2.4.1 评价指标	15
2.4.2 数据集	15
2.4.3 实验结果	16
2.4.4 实验分析	18
2.5 本章小结	19
第三章 基于深度强化学习的 NL2SQL 生成	21
3.1 研究问题	21
3.2 研究现状与相关技术	22

3.2.1	研究现状	22
3.2.2	相关技术	22
3.3	解决方案	30
3.3.1	增强解析器模型	30
3.3.2	状态与动作序列	31
3.3.3	编码器与解码器	33
3.3.4	过滤条件顺序问题和隐式列名问题	34
3.4	实验与分析	36
3.4.1	数据集与评价指标	36
3.4.2	数据预处理与模型参数设置	39
3.4.3	实验结果与分析	39
3.5	本章小结	44
第四章	基于多任务学习的 NL2SQL 生成	45
4.1	相关技术	45
4.1.1	注意力转换器模型	45
4.1.2	NLP 领域的迁移学习	46
4.1.3	NLP 领域的多任务学习	47
4.2	解决方案	47
4.2.1	TCR 模板	47
4.2.2	多任务学习网络	49
4.2.3	编码器	51
4.2.4	解码器	53
4.3	实验与分析	55
4.3.1	多任务学习实验	55
4.3.2	优化策略实验	57
4.3.3	实验分析	58
4.4	本章小结	59
第五章	总结与展望	61
5.1	本文贡献	61
5.2	展望	62
	参考文献	63

致 谢	69
攻读学位期间发表的学术论文	71

插图索引

2-1 INL2SQL 生成示例	5
2-2 基于映射的 INL2SQL 生成的总体方案	7
2-3 查询示例及其图模式	8
2-4 解析过程示例	9
2-5 隐藏节点插入过程示例	13
2-6 Classicmodels 数据库的数据库模式图	16
3-1 NL2SQL 的典型示例	21
3-2 智能系统的演变	23
3-3 生物神经元及其数学抽象	24
3-4 激活函数	25
3-5 神经网络的基础架构	25
3-6 反向传播机制	26
3-7 循环神经网络	27
3-8 长短期记忆网络	27
3-9 双向循环神经网络	28
3-10 注意力机制原理及可视化	29
3-11 强化学习范式	29
3-12 基于深度强化学习的 NL2SQL 生成的技术方案	30
3-13 基于深度强化学习的 NL2SQL 生成网络	33
3-14 WikiSQL 数据集中的问题类型分布	37
3-15 WikiSQL 数据集中问题、查询和表的分布	37
3-16 Spider 数据集样例	42
3-17 Spider 数据集的组成	43
4-1 缩放点积注意力和多头注意力	45
4-2 中文自然语言问题生成 SQL 查询语句的错误示例	48
4-3 TCR 示例	48
4-4 多任务学习网络的总体结构	49
4-5 多任务学习网络的详细结构	50

4-6 多任务学习网络输出来源	58
---------------------------	----

表格索引

2-1	解析树节点的类型	10
2-2	合法解析树结构规则	11
2-3	MAS 数据库数据统计	15
2-4	自然语言查询实例	17
2-5	模型生成 SQL 语句的准确性	17
3-1	动作清单	32
3-2	SQL 查询语句模板	38
3-3	WikiSQL 中验证集和测试集的准确度	39
3-4	使用不同集束大小的模型性能	40
3-5	ATIS 数据集上的实验结果	41
3-6	Spider 数据集上的实验结果	43
4-1	多任务学习的实验结果	55
4-2	多任务学习网络在不同训练策略下的实验结果	57

算法索引

2-1 解析树结构调整算法	12
-------------------------	----

第一章 绪论

1.1 研究背景

随着社会的不断发展，以 IT 和互联网技术为标志的信息产业不断地改变着人类的工作和生活方式。在此背景之下，数据库技术应运而生。它是一种建立在计算机存储设备上的仓库，可以将大量数据按照数据结构来组织、存储和管理。关系数据库中存储了大量的数据和信息。医疗、教育、金融等各个行业都在使用关系型数据库作为数据存储以及应用程序的基础。在软件系统的开发过程中，技术开发人员会频繁在系统后端运用 SQL 语句从而将软件系统与数据库系统连接起来，保证数据的流通。在软件的使用过程中，业务人员通过软件开发人员设计的数据库接口从数据库中获取所需信息。然而，报表与在线分析（OLAP）等需要灵活的数据查询的应用，业务人员也需要使用 SQL 语句进行数据查询定制。

SQL 语言作为一种数据库操作语言，本质上是一种编程语言。它需要操作人员经过数据库和 SQL 相关知识的培训且具有一定的专业知识后，才能比较熟练地进行 SQL 语句编程。除了要具备 SQL 和数据库技术的相关知识，使用者在实际操作时还需要对所涉及到的关系型数据库的模式信息有所了解，只有这样才能将各种操作需求转化为正确的 SQL 语句从而对数据库系统进行管理。随着数据库系统的应用场景越来越多，数据库的数据量和内部逻辑变得越来越复杂，即便是对经验丰富的软件开发人员或者数据库管理人员来说，想要将自己的查询意图转换为正确的 SQL 语句也变得越来越困难。对于那些希望依靠数据库来查询业务数据、生成报表或在线分析的业务人员来说其学习成本变得更高。

所以，如何降低 SQL 语言的学习成本、如何更快更好地生成 SQL 查询语句、如何使用更自然的方式生成 SQL 语言等问题一直都是研究人员想要解决的问题。本文尝试从两种方法去解决这些问题：使用交互式自然语言接口生成 SQL 查询语句以及将自然语言直接转换为 SQL 查询语句。

1.1.1 交互式自然语言接口生成 SQL 查询语句

交互式自然语言接口（Interactive Natural Language Interface，简称 INL），是自然语言处理与人机交互的交叉领域，旨在为人类提供通过自然语言与计算机交互的手段。从各种对话机器人，到今天各种智能穿戴设备装载的语音助手，人机交互领域和自然语言理解领域的专家们一直在朝建立真正智能的交互式自然语言接口这个目标不断探索。

交互式自然语言接口生成 SQL^[1] 也是人们关注的一个领域, 自上个世纪提出以来, 人们不断研究从自然语言生成 SQL 语句的可能性, 并且的确在研究过程中取得了一些令人振奋的成果。通过自然语言接口生成 SQL 的数据库管理系统, 原型已经出现在六十年代和七十年代初期, 那时候最著名的自然语言接口数据库是 Lunar^[2], 提供了月球岩石和化学数据库的自然语言接口。这个原型的实现, 是基于特定数据库的, 因此无法很容易地修改为和不同的数据库一起使用。之后出现了其他的自然语言接口数据库, 用户可以通过对话系统来定制查询, 并且这些系统可以配置不同的接口, 供不同的底层数据库调用^[3]。这时候的自然语言数据库系统使用语义语法, 是一种句法和语义处理的综合技术。之后, 还有关注于将自然语言输入转化为逻辑语言^[4] 的技术, 以此技术作为自然语言接口数据库的核心技术。

早期的 NLIDB (数据库的自然语言接口^[1]) 需要依靠为每个数据库单独定制的手工语法来进行查询, 这些手工语法的拓展性很差, 很难在其他数据库中进行使用。由于自然语言的表达方式十分复杂, 往往无法使用一个固定的格式和定义, 这些系统无法处理复杂的或者语义不确切的自然语言查询。同时, 一般的搜索引擎提供的方案或者之前的 NLIDB 的方案没有使用交互机制, 所产生的结果通常无法解释, 在语义的理解上容易出现“歧义”问题。

1.1.2 自然语言自动生成 SQL 查询语句

自然语言生成 SQL 查询语句 (Nature Language to SQL Statement, 简称 NL2SQL) 是 SQL 自动生成领域最高的要求和最难的挑战, 其旨在使用人类的纯自然语言作为输入并直接生成出符合语义意图的 SQL 查询语句。使用纯自然语言查询语句而不是自然语言接口作为输入, 意味着使用者几乎可以不需要有编程及数据库应用技术的知识就可以在数据库中执行 SQL 语句得到所需的数据信息。理想状态下, NL2SQL 将完全将业务与技术之间的鸿沟填平, 极大地提高软件开发效率和信息获取效率。

在上个世纪末就有学者提出了 NL2SQL 任务。在当时, 大多数的研究者提出的语义解析器^[5] 都依赖弱监督信号, 即以 SQL 查询语句在数据库中的执行结果来构造训练数据。他们希望解析器能够生成出 SQL 语句的基本逻辑形式。由于当时的 SQL 语句的逻辑形式往往由专家进行人工定义, 构造出的训练数据集往往非常小。同时产生的歧义问题使得设计出来的解析器的性能非常有限。2017 年, Victor Zhong^[6] 发布了一个由带注释的自然语言查询、SQL 查询语句和对应的数据库模式构成的大型数据集 WikiSQL。WikiSQL 中的自然语言问题的表示和数据库模式和内容上具有非常高的多样性。另一方面, 近年来深度学习技术的蓬勃发展使得 NL2SQL 任务重现曙光, 已经有不少研究者使用基于序列到序列的神经“机器翻译”系统^[6, 7] 或者序列到集合的模型^[8, 9] 试图解

决 NL2SQL 问题。然而，由不分先后顺序的过滤条件构成的 SQL 语句的执行结果往往是一致的，这会导致序列到序列的模型的训练十分困难。而序列到集合的模型可以有效避免过滤条件的顺序问题，但是也会使得模型丢失很多输入序列的内部依赖信息，导致生成的准确率无法进一步提升。

1.2 研究目标和研究内容

在此背景下，本文研究面向最终用户的 SQL 查询语句的自动化生成技术，结合解析树映射、语义解析、编码-解码器、注意力机制、深度强化学习和多任务学习等技术，提出并实现交互式自然语言接口生成 SQL 查询语句（INL2SQL）和自然语言生成 SQL 查询语句（NL2SQL）。

本文的 INL2SQL 研究思路是，结合自然语言解析技术，使用人机交互机制指导用户查询意图的解析过程，减轻自然语言解析的歧义问题和错误情况，实现自然语言接口自动生成 SQL 查询语句。

本文的 NL2SQL 研究思路是，结合编码-解码器和深度强化学习等技术，对更具难度的自然语言自动生成 SQL 查询语句技术进行研究。然后探索多任务学习技术，将中文-英文翻译任务和英文自然语言生成 SQL 查询语句技术有机结合，提高英文自然语言生成 SQL 查询语句的准确度，并实现中文自然语言生成 SQL 查询语句。

具体研究内容包括：

1) 研究基于意图交互理解的 INL2SQL 的技术与方法。通过依赖解析树生成、解析树节点映射、解析树优化重构、查询树翻译模块对用户输入的查询进行意图的解析并映射到 SQL 查询语句上。通过交互式对话器和用户接口模块对意图解析和映射进行补充和重构，减少自然语言解析中出现的歧义问题和错误情况，提升准确性。

2) 研究基于深度强化学习的 NL2SQL 的技术与方法。在离线训练阶段，将 WikiSQL 中的数据进行序列表示后输入给网络模型，模型生成 SQL 查询语句后在数据库中执行，再使用奖励函数构造奖励用于强化网络模型。在在线生成阶段用户输入自然语言查询语句及数据库模式，训练好的网络模型将生成符合用户查询意图的 SQL 查询语句。研究神经网络模型的结构，由编码器和解码器构成并结合了自注意力机制。参考强化学习的基本范式，将网络模型的学习目标转换为策略的优化问题并给出了模型的状态和动作的定义。研究解决 SQL 查询语句中的过滤条件的顺序问题、隐式列名问题的解决方法。

3) 研究基于多任务学习的 NL2SQL 的技术与方法。研究不同任务的迁移学习技术，提出多任务学习的 NL2SQL 生成的解决方案，旨在提高 NL2SQL 生成的准确性，同时实现多个任务的推理。多任务协同的一个典型应用是通过“英文 NL2SQL + 中文至英文翻译”，解决中文自然语言生成 SQL 查询语句的问题。本文将研究神经网络模型的结构，

使用由编码器和解码器构成的多任务网络模型，设计编码和解码过程的所有阶段。

4) 实验。使用 Classicmodels、WikiSQL、ATIS 和 Spider 数据来评估基于映射的 INL2SQL 方法、基于深度强化学习的 NL2SQL 方法和基于多任务学习的 NL2SQL 方法的有效性、准确性和可拓展性。

1.3 论文结构

全文共由五章组成：

第一章 绪论，主要阐述了本文的研究背景、研究路线、研究目标和研究内容，并对全文结构进行总览。

第二章 基于映射的 INL2SQL 生成，分析与定义 INL2SQL 问题，提出了一种基于映射的 INL2SQL 的方法。简单介绍了解析过程和交互方式，详细阐述了依赖解析树生成、解析树节点映射、解析树优化重构、查询树翻译模块的实现方法。使用 Classicmodels 和 MAS 数据集进行了实验，并对实验结果进行了分析。

第三章 基于深度强化学习的 NL2SQL 生成，分析与定义 NL2SQL 问题，提出了一种基于深度强化学习的 NL2SQL 的方法。提出了由编码器和解码器构成的神经网络模型结构，并分别对编码过程和解码过程中的各个阶段进行了详细阐述。提出将网络模型的学习目标转换为策略的优化问题，并对给出了模型的状态和动作的定义。提出了解决 SQL 查询语句中的过滤条件的顺序问题、隐式列名问题的解决方法。使用 WikiSQL、ATIS、Spider 数据集进行实验，并对实验结果进行了分析。

第四章 基于多任务学习的 NL2SQL 生成，提出一种基于多任务学习的 NL2SQL 生成的解决方案。设计 TCR 模板对中文自然语言转换为英文自然语言任务和英文自然语言转换为 SQL 查询语句任务进行统一。提出由编码器和解码器构成的多任务网络模型，并对编码和解码过程的所有阶段进行阐述。进行了多任务网络 and 不同优化策略下的实验，并对实验结果进行了分析。

第五章 总结与展望，总结本文当前已经完成的工作，给出本文主要的贡献与创新点，对下一步的研究工作进行展望。

第二章 基于映射的 INL2SQL 生成

本章研究交互式自然语言接口生成 SQL 查询语句（INL2SQL）的技术与方法。

2.1 研究问题

一直以来,自然语言接口是人机交互领域的终极追求,也是人机交互、机器学习领域专家孜孜不倦钻研探索的热门问题。交互式自然语言接口生成 SQL 查询语句(INL2SQL)的关键问题就是怎样使得系统能在与用户的多轮交互之下理解到用户的查询意图,并结合数据库模式直接生成符合查询意图的 SQL 语句。其主要过程为:用户首先输入自然语言查询语句以及给出对应的数据库模式,系统接收到输入后理解输入,并和用户产生多轮交互,在交互完成并确认输出后将对应的 SQL 查询语句及执行结果输出。

输入: ‘Return the altitude of Willis Tower in Chicago’

Rank	Name	Location	Height(ft)	Floor	Year
1	One World Trade Center	New York City	1,776	104	2014
2	Willis Tower	Chicago	1,451	108	1974

输出: {‘Name’=‘Willis Tower ’; ‘Location’=‘Chicago’}, {‘select’=[‘Height(ft)’,’Floor’,’Year’]}

输入: {‘select’=‘Height(ft)’}

输出: {‘sql’=‘**SELECT** ‘Height(ft)’ **WHERE** Name=‘Willis Tower ’ **AND** Location=‘Chicago’;
‘result’=‘1,451’}

图 2-1 INL2SQL 生成示例

Figure 2-1 An Example of Interactive Nature Language to SQL Query Statement

图2-1中给出了 INL2SQL 生成的一个示例。用户首先输入自然语言查询语句“Return the altitude of Willis Tower in Chicago”。系统根据给定的数据库模式,判断出两个有效过滤条件即 ‘Name’ = ‘Willis Tower ’ 和 ‘Location’ = ‘Chicago’ 但不确认聚合函数是否为 ‘SELECT’ 及其对象是否为 ‘Height(ft)’。系统返回一个包含 ‘Name’ = ‘Willis Tower ’; ‘Location’ = ‘Chicago’ 和 ‘select’ =[‘Height(ft)’ ,’ Floor’ ,’ Year’] 的交互项。其中 ‘Name’ = ‘Willis Tower ’; ‘Location’ = ‘Chicago’ 表示为已经确认的信

息, 'select' = ['Height(ft)', 'Floor', 'Year'] 为 json 格式表示需要用户在 'Height(ft)', 'Floor', 'Year' 中做出选择。用户接受到交互信息后进行选择并发送包含 'select' = 'Height(ft)' 的 json 数据。最后, 系统在多轮交互并确认输出有效后将对应的 SQL 查询语句 'SELECT 'Height(ft)' WHERE Name= 'Willis Tower' AND Location= 'Chicago' 及执行结果 '1,451' 输出。

2.2 相关工作

在软件产品的开发与使用过程中, 非专家用户常常会在指定的关系型数据库上使用关键字搜索^[10-13]来进行实时的查询。所以近年以来, 有很多的研究人员对关键字搜索领域进行研究^[14-18]。关键字搜索的目的不是通过输入的关键字的集合来找到与这些关键字相关联的数据, 而是通过这些关键字来推测并解析出其背后想要表达的查询意图及对应的自然语言。在这些研究中, 有的方法通过聚合函数^[14]、布尔运算符^[15]、查询语句片段^[17]等方式对关键字进行拓展。现在看来, 这些研究内容是解决自然语言查询这一挑战的奠基者。本文所提出的解决方案能够支持更加丰富的查询, 使得用户可以使用语义更加复杂的语句进行查询。

数据库的自然语言接口 (NLIDB) 已经被研究人员研究了很长的时间^[1]。早期的 NLIDB 需要依靠为每个数据库单独定制的手工语法来进行查询, 这些手工语法的拓展性很差, 很难在其他数据库中进行使用。相比之下, 本文所提出的解决方案以生成 SQL 查询语句作为目的, 具有很好的通用性, 可以被移植到其他的数据库上使用。

NLIDB 在使用上最大的问题在于其所依赖的信息很有限, 正常的自然语言往往是没有一个固定的格式和语义^[19]。这也就导致了 NLIDB 无法准确地推断用户输入的查询意图。为了解决可靠性的问题, Popescu 等人^[19, 20]采用了 PRECISE 方法, 将输入的自然语言查询划分为语义更加容易被解析的查询片段, 并将这些查询片段更为精确地转换为 SQL 查询语句。但是, PRECISE 无法处理那些语义不确切或者难以处理的自然语言查询。相比而言, 本文提出的解决方案通过与用户的多轮交互, 可以较好地解决语义不明确的问题。

也有很多文献^[1, 21, 22]提出过交互式 NLIDB 的想法, 早期交互式 NLIDB^[1, 21]主要目标在于从查询生成对应的结果。而 NaLIX^[22]则更进一步, 当用户的查询超出模型的语义理解能力的范围之外时会把相应的重构查询的建议返回给用户, 这种策略会大大减少用户在使用时对其查询进行重构的负担。然而, NaLIX 对输入的查询超过模型的语义理解能力的处理方式不太正确。而在本文提出的解决方案中, 对于给定的自然语言查询语句, 系统会与用户多轮交互并向用户解释意图解析与 SQL 生成的过程, 从而对查询进行重构, 解决歧义问题。所以, 在与用户的多轮反馈与交互下, 用户可以输入较为复杂

的查询，其生成的 SQL 查询语句可以包含多级聚合操作、嵌套以及各种类型的连接操作等。

2.3 解决方案

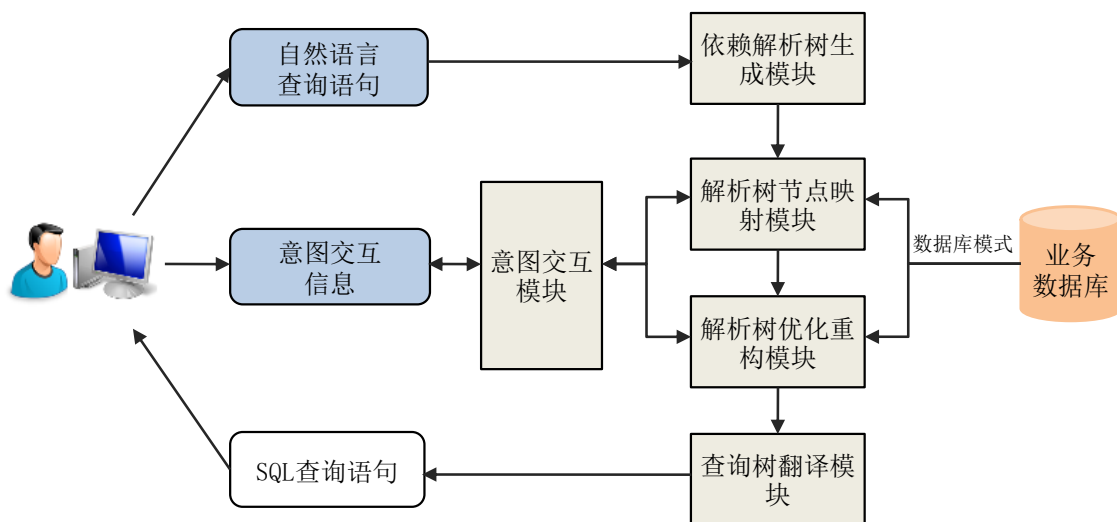


图 2-2 基于映射的 INL2SQL 生成的解决方案

Figure 2-2 Approach on Interactive Nature Language to SQL Query Statement through Mapping

图2-2是基于映射的 INL2SQL 生成的解决方案，它包含依赖解析树生成、解析树节点映射、解析树优化重构、查询树翻译、意图交互五个模块：

1. 依赖解析树生成：将用户输入的、以自然语言表示的查询意图，应用自然语言理解技术，转化为依赖解析树，即将词语进行词性标注，识别出词语之间的关系，并将其组织成一个树状结构。详见2.3.1节。
2. 解析树节点映射：根据解析树节点对应的词语和数据库模式、SQL 语法等信息，将解析树节点映射为 SQL 语法组件。在这个过程中，如果节点的映射有多个候选答案，意图交互模块会发起与用户的交互，将多个候选映射展示给用户，让用户来进行选择。详见2.3.2节。
3. 意图交互：管理解析过程与用户的交互，在适当的时候与用户进行交互，让用户对解析过程进行反馈与指导。
4. 解析树优化重构：节点映射完毕后，解析树节点经过系统匹配和用户指导后，得

- 到了比较准确的结果，但解析树的结构仍是最初由依赖解析树生成得到的结构，这一原始结构的准确度并不高，受限于自然语言的复杂性和省略性，可能会有错误关系、缺失关系、缺失节点等等。因此系统将根据算法和规则，修正错误关系，补全缺失节点和缺失关系，得到较为准确的解析树，称为查询树。详见2.3.3节。
5. 查询树翻译：解析树的结构已经符合 SQL 语法，节点映射结果也对应于真实的 SQL 语法、数据库模式或数据，可以很自然地将树状结构翻译为 SQL 语句，最后将 SQL 语句（及查询结果）返回给用户。详见2.3.4节。




图 2-3 查询示例及其图模式

Figure 2-3 Query Examples and Graph Schema

需要特别说明的是，一般的搜索引擎提供的方案或者之前的 NLIDB 的方案所产生的结果通常无法解释。例如，假设用户的输入是图2-3中的输入 1，使用之前的方案可以得到结果为数字 5，而用户无法知道这个答案是否正确；除此之外，由于自然语言的表达十分复杂，用户的输入可能是模棱两可的。例如，假设用户的输入是图2-3中的输入 1，查询语句中所使用的单词是“publication”，而在业务数据库中，“publication”在数据库中对应的可能是表中的“article”，“journal”等字段。因此，在基于映射的 INL2SQL 中，本文并不是直接产生查询的结果，而是向用户解释解析的过程，并通过多轮的交互修复解析中产生的“歧义”问题。

在此，先给出基于映射的 INL2SQL 生成的整个解析过程的示例（如图2-4所示），再对解决方案中的每个模块进行详细阐述。第一步，通过依赖解析树生成模块，系统将用户的自然语言查询输入（图2-3中的输入 2）转换为一颗简单的语法解析树（图2-4(1)）。

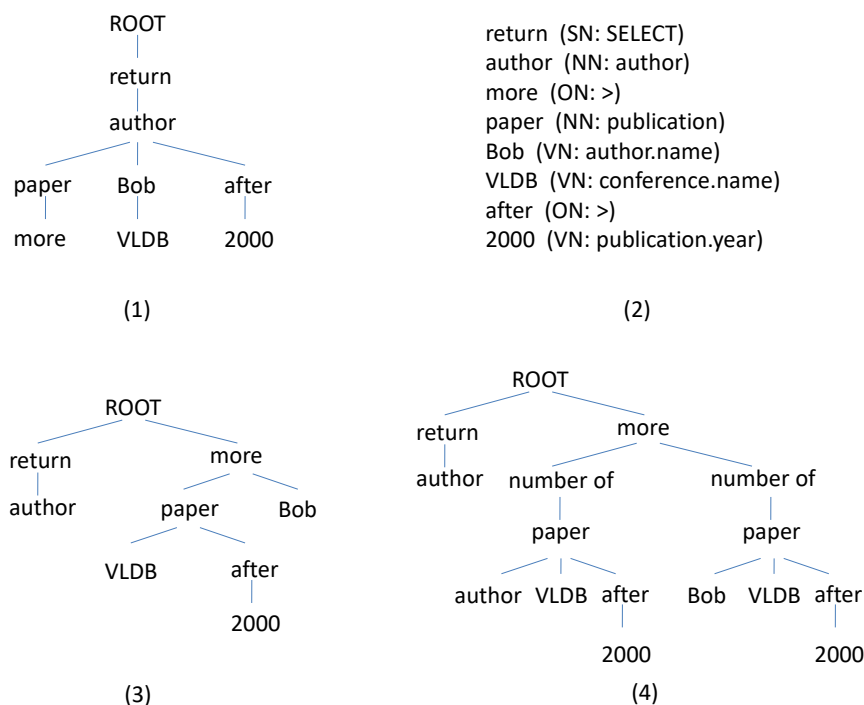


图 2-4 解析过程示例

Figure 2-4 Example of Parsing Process

第二步，解析树节点映射模块为解析树种的每个节点生成一个最佳映射（图2-4(2)），并通过意图交互模块向用户通知“VLDB”节点在数据库模式中可以映射为“conference”和“journal”而系统选择了“conference”作为其默认映射。第三步，解析树优化重构模块将根据最佳映射对解析树进行重构和调整，生成k个有效的解析树。同时，意图交互模块会结合自然语言模板将这k个候选的解析树告知用户并让用户进行选择，例如：“return the authors, where the papers of the author in VLDB after 2000 is more than Bob”。被选择的最佳的解析树如图2-4(3)。之后，通过插入一些隐藏节点，解析树被实例化为图2-4(4)，与用户的交互为“return the authors, where the number of papers of the author in VLDB after 2000 is more than the number of paper of Bob in VLDB after 2000”。若用户需要取消in VLDB 和after 2000，系统将继续执行第二步和第三步。第四步，查询树翻译模块将结合 SQL 语句的表达式将最终确认的解析树转换为 SQL 查询语句并返回给用户。

接下来，本文将详细阐述依赖解析树模块、解析树节点映射模块、解析树优化重构模块、查询树翻译器的设计思路和实现细节。

2.3.1 依赖解析树生成

本模块将用户输入的自然语言查询解析为解析树，主要内容包含词语的词性标注、关系提取等。

在具体实现过程中，这一模块基于 Stanford Parser^[23] 实现。Stanford Parser 是斯坦福大学推出的自然语言处理工具，提供依赖解析、命名实体识别、词性标注、情感分析、机器翻译等多种功能。本模块调用该工具，使用依赖解析的相关接口将自然语言查询解析为依赖解析树。如图2-4(1)所示，依赖解析树的每个节点为用户输入的单词或短语，每条边为提取出的单词之间的语义依赖关系。

2.3.2 解析树节点映射

本模块将依赖解析树的节点对应的词语，映射到 SQL 组件上。解析树节点的类型定义如表2-1所示。

表 2-1 解析树节点的类型
Table 2-1 Different Types of Nodes

节点类型	对应的 SQL 组件
选择节点 (SN)	SELECT
操作符节点 (ON)	一个操作符，如等于 (“=”)、小于 (“<”)
聚合函数节点 (FN)	一个聚合函数，如 AVG、MAX
名字节点 (NN)	业务数据库中的一个数据表的名字，或数据表的一个字段的名字
值节点 (VN)	业务数据库中某字段的一个值
度量节点 (QN)	ALL, ANY, EACH
逻辑节点 (LN)	AND, OR, NOT

其中名字节点和值节点是与当前应用的业务数据库有关，其余五种节点都与业务数据库无关，仅与 SQL 语法规则相关。所以，本系统建立了一个五种与业务数据库无关的节点类型与自然语言单词的词典映射。映射过程的实现如下：对每一个解析树节点对应的单词 n ，分别计算其与业务数据库元数据、存储数据、词典映射中词语 v 的相似度 $Sim_{wup}(n, v)$ ， $Sim_{gram}(n, v)$ 的定义如公式2-1所示：

$$Sim(n, v) = \max(Sim_{wup}(n, v), Sim_{gram}(n, v)) \quad (2-1)$$

其中 $Sim_{wup}(n, v)$ 为 n 和 v 的 WUP 相似度^[24]， $Sim_{gram}(n, v)$ 为 n 和 v 的 q-gram 的

Jaccard 相似度的平方根^[25]。经公式计算，可以得到节点单词 n 与所有 SQL 组件的相似度；对相似度进行排序，可以得到前五相似的 SQL 组件，如果前五相似的 SQL 组件的相似度 $Sim(n, v)$ 的值差别较大，则直接以相似度最高的 SQL 组件作为当前单词 n 的映射，并赋予该组件对应的节点类型；若前五相似的 SQL 组件的相似度差别较小，则视作歧义，将候选的 SQL 组件返回给用户，让用户来进行选择，最后用户选择的结果会作为当前节点的映射。

2.3.3 解析树优化重构

节点映射完成后，需要对解析树的结构进行重构，保证解析树的结构能有较高的准确性。由于解析树可能会存在关系解析错误和节点关系缺失，所以这一模块对于解析树的优化重构会分为两个步骤进行，分别为结构调整和隐藏节点插入。

2.3.3.1 结构调整

表 2-2 合法解析树结构规则

Table 2-2 Grammar of Valid Parse Trees

1	$Q \rightarrow (SClause) (ComplexCondition) *$
2	$SClause \rightarrow SELECT + GNP$
3	$ComplexCondition \rightarrow ON + (leftSubtree * rightSubtree)$
4	$leftSubtree \rightarrow GNP$
5	$rightSubtree \rightarrow GNP VN MIN MAX$
6	$GNP \rightarrow (FN + GNP) NP$
7	$NP \rightarrow NN + (NN) * (Condition) *$
8	$condition \rightarrow VN (ON + VN)$

在进行结构调整之前，首先定义什么样的树结构是好的、合法的。本文从两个角度来考虑这个问题：第一点是树结构与经依赖解析器解析后的原始结构的差别有多大；第二点是树结构是否符合 SQL 的语法，这一点的评估可以根据表2-2的定义来确定^[26]。

表2-2根据 SQL 语句的语法，结合了树状结构，定义了能合理的转化为 SQL 语句的语法树应该满足什么样的规则，这样的语法树在本文中称为查询树。在表2-2中，“+”代表父子节点的关系，“*”代表兄弟节点的关系，上标“*”代表可重复出现的兄弟节点，“|”代表“或者关系”，表示当前节点可能存在的情况。

算法 2-1 解析树结构调整算法

输出：结构调整之后的解析树结果集

```

1: results  $\leftarrow$  empty_set()
2: priorityQueue  $\leftarrow$  empty_priority_queue()
3: priorityQueue  $\leftarrow$  priorityQueue + parseTree
4: hash_table  $\leftarrow$  empty_set()
5: hash_table  $\leftarrow$  hash_table + hash(parseTree)
6: while priorityQueue  $\neq$  empty_priority_queue() do
7:   tree  $\leftarrow$  priorityQueue.pop()
8:   treeList  $\leftarrow$  adjust(tree)
9:   for adjustTree in treeList do
10:    if hash(adjustTree) not in hash_table and adjustTree.edit < t then
11:      adjustTree.edit  $\leftarrow$  tree.edit + 1
12:      hash_table  $\leftarrow$  hash_table + hash(adjustTree)
13:      if evaluate(adjustTree)  $\geq$  evaluate(tree) then
14:        priorityQueue.add(tree)
15:      end if
16:      if adjustTree is valid then
17:        results.add(adjustTree)
18:      end if
19:    end if
20:  end for
21: end while
22: results  $\leftarrow$  rank(results)
23: return results

```

算法2-1展示了结构调整的算法，算法的基本思想是，建立一个优先级队列，对于当前的解析树，调用 `adjust()` 函数（第 8 行），通过一次移动子树操作，生成在这一次操作后所有可能的结构；然后记录当前树的哈希值（第 12 行），防止之后出现重复的树结构；若当前树结构没有出现过（第 10 行），且 `edit` 值小于一个阈值，则对此树进行下一步操作；由于移动了一次子树，返回的树的 `edit` 属性加一（第 11 行），这一属性将用来评估生成的树结构与原始结构的差异；调用 `evaluate()` 函数，记录当前结构有多少节点不满足表2-2设定的规则，不满足规则的节点数将用来评估树结构在语法上的合法性；综合这两方面评估标准，为树打分，如果分数比之前的树结构要高，则加入优先级队列；若该树完全符合语法规则，则视为一颗查询树，加入 `result` 集合；之后对优先级队列内的树结构重复以上操作，直到优先级队列为空；最后根据评估分数对 `result` 集合排序，将结果返回。

结构调整之后的解析树结果集，将会通过交互式对话器，与用户进行交互，因为结果集中的解析树虽然都符合 SQL 语法规则，但仍有可能存在与用户意图不同的情况，如 `SELECT` 子句中的名字节点和 `WHERE` 子句中的名字节点，位置可能会互换，虽然仍然符合 SQL 语法规则，但与原始查询意图已经有比较大的差别了。所以，在这里需要再一次应用人机交互机制，让用户来选择结果集中与自己的查询意图比较相似的解析树。交互完成后，筛选出的结果集，会进入下一步——隐藏节点插入。

2.3.3.2 隐藏节点插入

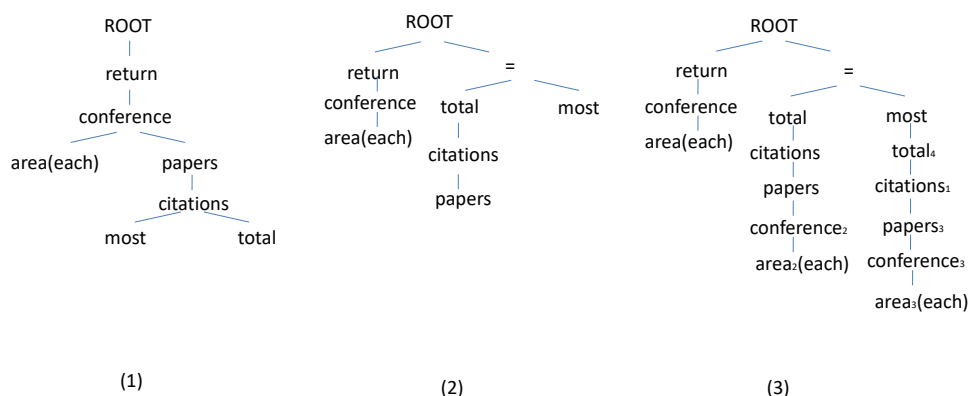


图 2-5 隐藏节点插入过程示例

Figure 2-5 Steps of Parsing

结构调整完成后，对经过排序和用户交互筛选后的结果集合，进行隐藏节点插入。

图2-5展示了图2-3中的输入 3 从简单的解析树、有效解析树再到隐藏节点插入后的解析树的过程。在给出隐藏节点插入的方法之前，先给出需要用到的概念定义，即“核心节点”。核心节点指的是在节点类型为 `leftSubtree` 和 `rightSubtree` 的情况下（表2-2），`leftSubtree`（`rightSubtree`）的所有子节点中，高度最高的名称节点被称为核心节点。

经过研究，需要进行隐藏节点插入的情况有以下几种：

1. 左子树（`leftSubtree`）与右子树（`rightSubtree`）的核心节点对应了不同的 SQL 组件，即认为右子树真正的核心节点在自然语言表达时被省略了^[27]；这是十分常见的现象，因为人在进行自然语言表达时，对两个值进行比较时，会很自然的省略掉后者的一部分，如“I have more books than yours”这句话，就将最后的“your books”给省略成了“yours”；
2. 左右子树的约束条件应该一致，如果不一致，则认为右子树一部分约束条件被省略了，如“return authors whose papers published in 2018 more than Jack’s”这句话，过滤条件的左子树有“in 2018”这一约束，而右子树在解析之后没有这一约束，事实上右子树的这一约束被隐藏了，需要作为隐藏节点插入进去；
3. 某些函数会被省略，如聚合函数“COUNT”，在自然语言表达中经常会被省略，如“I have more books than yours”这句话，“the number of”就被省略了。在树结构中，如果过滤条件的操作符为“more”、“less”等词语，而左右子树的核心节点对应的是非数字类型的 SQL 组件，那么就认为“COUNT”被省略了，需要作为隐藏节点插入解析树。

进行隐藏节点插入之后，查询树的结构就比较完整了，将会输入下一模块进行翻译。

2.3.4 查询树翻译

这一阶段的查询树已经在节点映射、树结构、完整性方面都比较可信、合法了，翻译步骤如下：

1. 根据表2-2中的树结构，在 `SClause` 子树下的结构为 `SELECT` 子句，读取 `SClause` 下的名称节点，根据对应的 SQL 组件（如果 SQL 组件对应某数据表，该数据表会预定义一个核心字段，如用户的名字、城市的名称，该数据表的核心字段将作为结果返回），填充入 `SELECT` 子句，并记录 SQL 组件对应的数据表，以备 `FROM` 子句的生成。
2. 在 `ComplexCondition` 子树下的结构为 `WHERE` 子句，分别读取左子树和右子树核心节点对应的 SQL 组件，记录下 SQL 组件对应的数据表，并查看左右子树中所有的节点，根据其节点类型，将其翻译为对应的 SQL 组件，并应用于核心节点；左右子树解析完后，以操作符连接左右子树，将其填充入 `WHERE` 子句。

3. 根据之前记录的相关数据表，生成 SQL 语句的 FROM 子句。
4. 将三部分按照语法连接起来，作为合法的 SQL 语句返回给用户。

2.4 实验与分析

为了评估基于映射的 INL2SQL 方法的准确性，本文采用 Classicmodels 和 MAS 数据集进行了实验。

2.4.1 评价指标

INL2SQL 的目标是尽可能让使用者使用更加自然的自然语言的方式来生成 SQL 查询语句，如何评价 INL2SQL 系统的有效性是其中比较有挑战的问题。在此背景下，传统的信息检索所使用的指标（如精确度和召回度）不太适用与这个场景。例如，当生成的 SQL 语句有效时，精确度为 100%；而当生成的 SQL 不完全有效时，得到的精确度往往为 0%，这不能很好的显示出系统的有效性。因此，本文采用的评价指标为准确性，其定义为输入的查询语句经过多轮交互后完美符合用户期望的比例，在最后一次交互时用户确认生成有效时记为正确生成，用户在任意时刻认为 SQL 生成无效时记为错误生成。需要说明的是，即使最后生成的 SQL 语句与标准答案高度一致但用户认为此次生成无效时，本文也会认为是一次错误生成。因此，该评价指标是更为严格的。

2.4.2 数据集

表 2-3 MAS 数据库数据统计

Table 2-3 MAS Database Statistics

表名	数据量	表名	数据量
Publica	2.45M	Author	1.25M
cite	20.3M	Domain	24
Conference	2.9K	Journal	1.1K
Organiza	11K	Keywords	37K

本次实验所使用的业务数据库为 MySQL 的样例数据库 Classicmodels 以及 MAS(Microsoft Academic Search) 数据库，图2-6为 Classicmodels 数据库的数据库模式图，图2-3和表2-3为 MAS 的模式图和数据统计。实验所使用的自然语言查询数据集根据查询意图的复杂度，分为简单、中等、困难三类。Classicmodels 数据集中的每种类别，提




图 2-6 Classicmodels 数据库的数据库模式图

Figure 2-6 Database Schema of Classicmodels Database

出了 20 条自然语言查询，共计 60 条，用来测试模型的有效性。MAS 数据集中的每个类别有 100 条自然语言查询，共计 300 条，用于测试模型的准确性。

表2-4给出了三种类别的自然语言查询示例，上半部分为 Classicmodels 数据集，下半部分为 MAS 数据集。

2.4.3 实验结果

首先将所有自然语言查询语句，输入系统，经过各组件的处理，得到系统生成的 SQL 语句，再判断其是否正确表达了自然语言查询语句的意图。实验结果如表2-5所示。实验检验了没有用户交互和有交互的场景下，模型生成 SQL 语句的准确性。需要说明的是，无论有无交互，在没有选择合适树结构时，导致解析树结构调整之后有多个候选结果，最后返回结果也会有多个，故只要返回结果中包含正确 SQL 语句，就视做 SQL 生成正确。从模型在 Classicmodels 数据集上的实验结果来看，模型在有交互的场景下的准确性相较无交互的场景下有较大提升，证明了本文模型的可用性。从在 MAS 数据集上的实验结果来看，模型在有交互的情况下在简单、中等、困难的场景下的表现为

表 2-4 自然语言查询实例

Table 2-4 Instances of Natural Qanguage Query

查询语句复杂度	Classicmodels 数据集
简单	return all the custormers
中等	return all the offices in London
困难	return the city of office that has an employee named Diane
查询语句复杂度	MAS 数据集
简单	return all the conferences in database area
中等	return the number of papers in each database conference
困难	return the author who has the most publications in database area

表 2-5 模型生成 SQL 语句的准确性

Table 2-5 The Accuracy of Generating SQL Statements

数据集	简单	中等	困难
Classicmodels 数据集（无交互）	65%	50%	15%
Classicmodels 数据集（有交互）	100%	80%	35%
MAS 数据集准确率(无交互)	63%	47%	29%
MAS 数据集准确率(有交互)	100%	93%	71%

100%, 93%, 71%, 超过了 66.7%, 54.5%, 54.5% 的最高水平^[15]。

2.4.4 实验分析

1. 经过如上实验, 分别检验了完整模型在有无交互机制的场景下生成 SQL 语句的准确性。可以看出, 交互机制对于模型的准确性有很大的提升; 而加入了交互机制后, 模型可以比较准确的处理简单和中等复杂度的查询意图, 即便是复杂度较高的查询意图, 本文提出的模型仍然可以正确生成一部分困难复杂度的 SQL 语句。在实验过程中, 经常出现节点歧义需要映射, 如 “price” 一词可以映射到 “products” 表中的 “buyPrice”, 也有可能映射到 “orderdetails” 表中的 “priceEach”。那么对于测试语句 “return order details whose price is higher than 50”, 如果没有交互机制, 对于 “price” 这个节点的映射就会优先映射到 “products” 中的 “buyPrice”, 而实际上应该映射到 “orderdetails” 表中的 “priceEach”。可以看出, 交互机制在节点映射这一部分准确率的提升, 大大影响了整体模型的准确率。
2. 在 Classicmodels 数据集上构造的自然语句查询意图数据集中, 简单复杂度的查询意图大体上是返回某数据表中某一字段, 中等复杂度的查询意图会添加一些聚合函数和简单过滤条件, 困难复杂度的意图会增加更多的聚合函数和跨表查询, 总体上来说结构都比较简单。在表2-5所示的结果中, 困难复杂度意图的错误生成情况, 一部分来源于查询意图对应的 SQL 语句需要子查询, 如 “return the customer who has the most orders”。目前的模型还不能很好的处理这种情况, 在解析树语法和翻译过程中都还没考虑子查询的情况, 这可能是接下来需要进一步进行的工作, 即提升模型的处理能力, 使其能处理更复杂的查询意图。
3. 目前模型基于相似度的节点映射机制仍然有不足之处, 如 “return the mobile number of customer whose name is Australian Gift Network” 这一查询意图, 对于顾客名称 “Australian Gift Network”, 系统会将其映射为三个不同的节点, 导致生成出错。尽管模型对于数据库模式中的一些连接词或短语, 如 “the number of”、“customer name”, 进行了特殊处理, 但对于上文所示的这些特殊短语或词语, 目前没有较好的方法来进行处理。
4. 本文自行建立了一个解析树节点类型与自然语言单词的映射词典 (表2-1), 能处理一些常见的单词与 SQL 语法的对应关系, 如 “return”、“in”、“have”、“thenumberof”, 但映射关系仍然不足, 所以本实验所使用的测试查询意图都需要使用这些比较固定的词语来构建。事实上, 自然语言的表达非常多样, 如果要增加模型的处理能力, 扩充这个映射词典也是非常必要的。

5. 尽管人机交互机制对于节点映射的准确率有较大提升，但根据观察，立足于目前数据量较小、数据库模式简单的前提下，这一机制能保证映射相似度排名前五的 SQL 组件包含正确的映射关系；但随着数据库数据量的增加、数据库模式的复杂化，目前节点映射的相似度计算机制，可能无法确保正确的 SQL 组件能有较高的相似度。

2.5 本章小结

本章提出了交互式自然语言接口生成 SQL 语句的方法与技术，基本思想是结合自然语言解析技术，使用人机交互的方式指导解析过程，减轻自然语言解析的歧义问题和错误情况，相比于纯自然语言解析技术，大大提升了准确性。本章针对自然语言生成 SQL 语句的方法的准确性进行了实验。实验数据为 classicmodels 数据集和 MAS 数据集及其对应的自然语言意图数据集，分别包含简单、中等、困难三种复杂度的查询意图。评估了本方法在有无交互机制的场景下的性能，并给出了实验结果。结果发现，本方法能出色地处理简单和中等复杂度的查询意图，能够较好地处理困难复杂度的查询意图，并且交互机制对准确度的提升非常显著。但本方法存在无法处理子查询、自然语言意图形式比较固定、无法处理特殊词组等问题，需要进一步进行提升和改进。

第三章 基于深度强化学习的 NL2SQL 生成

本章基于深度强化学习技术，研究并提出了自然语言生成 SQL 查询语句 (NL2SQL) 的方法。

3.1 研究问题

NL2SQL 的输入表示为 x ，其包含由单词 w_i 组成的自然语言问题 w 以及由列名 c_j 组成的业务数据库单张表的模式 c （其中，列名 c_j 可由单个或多个单词组成）。输出为一条可执行的 SQL 查询语句 y 以及其在业务数据库中执行的结果 r 。现通过给出 NL2SQL 任务中一个典型的例子（如图3-1所示）来进一步说明。

输入：What is the height of Willis Tower in Chicago?

Rank	Name	Location	Height(ft)	Floor	Year
1	One World Trade Center	New York City	1,776	104	2014
2	Willis Tower	Chicago	1,451	108	1974

输出：SELECT 'Height(ft)' WHERE Name='Willis Tower' AND Location='Chicago'

执行结果：1,451

图 3-1 NL2SQL 的一个典型示例

Figure 3-1 An Example of NL2SQL

在图3-1中， w 为自然语言问题 “What is the height of Willis Tower in Chicago?”，其中 w_0, w_1, w_2, \dots 分别为单词 “What”、“is”、“the” 等。 c 库业务数据库的模式 “Name Location Height(ft) Floor Year”，其中 c_0, c_1, c_2, \dots 分别为单词 “Name”、“Location”、“Height(ft)” 等。输入 x 是由 w 和 c 组成的集合。输出 y 在该示例中对应的 SQL 查询语句为 “SELECT ‘Height(ft)’ WHERE Name= ‘Willis Tower’ AND Location= ‘Chicago’”，其在业务数据库中执行的结果 r 为 1451。

NL2SQL 的研究问题在于如何去理解自然语言语句的意图并在一次交互的状态下将意图映射到 SQL 查询语句上，即在知道数据库模式 c 的状态下，将用户输入的自然语言问题 w 转换为一条 SQL 查询语句 y 并得到数据库执行结果 r 。

3.2 研究现状与相关技术

3.2.1 研究现状

NL2SQL (Nature Language To SQL Statement) 任务可以看作是一种语义解析的任务。在以前, 大多数的研究者提出的语义解析器都依赖弱监督信号, 即以 SQL 查询语句在数据库中的执行结果来构造训练数据^[5]。他们希望能通过训练解析器来生成出 SQL 语句的基本逻辑形式。然而, 由于 SQL 语句的逻辑形式往往由人工定义, 构造出的训练数据集往往非常小。同时歧义问题 (不同逻辑形式的语句可能产生相同的执行结果, 并且无法区分哪种形式是正确结果并作为监督信号) 使得设计出来的解析器的性能非常有限。在 2017 年, Victor Zhong^[6] 发布了一个由带注释的自然语言查询、SQL 查询语句和对应的数据库模式构成的大型数据集 WikiSQL。

尽管与之前的 SQL 生成领域的 ATIS 和 GeoQuery 数据集相比, WikiSQL 数据集覆盖的 SQL 语法较少, 但是它的优势在于数据集很大并且在自然语言问题的表示和数据库模式和内容上有着非常高的多样性。这也意味着神经网络和深度学习技术可以更好地应用在 NL2SQL 这个领域上。

近几年来, 已经有大量的研究者^[6-9, 28-30] 在 NL2SQL 这个领域进行研究并在 WikiSQL 数据集上进行实验评估。目前主要的研究思路有两种, 一种是用基于序列到序列的神经“机器翻译”系统^[6, 7], 另一种是将 SQL 查询划分为多个部分并使用不同的模块进行生成^[8, 9]。第一种方案的挑战在于可能会有多种语义一致的逻辑形式对应于同一个查询结果, 由不分先后顺序的过滤条件构成的 SQL 语句的执行结果却是一致的, 而序列到序列的模型往往需要一种标准格式才能训练^[6]。为了解决这个问题, 作者使用了强化学习来对解析器的所有正确预测进行奖励。第二种方案不使用序列到序列模型, 而是使用序列到集合的模型先去预测数据表中的哪些列名应该出现在最后的 SQL 语句中, 再在这些列名的基础上分别预测剩余的部分。这种方法可以有效避免过滤条件的顺序问题, 但是也会使得模型丢失很多输入序列的内部依赖信息。本文分析了两种研究思路的优劣, 提出了一种新的基于序列到动作的解析器模型。

3.2.2 相关技术

本节将简要阐述 NL2SQL 中将要用到的机器学习模型与技术。

3.2.2.1 深度学习

从网络搜索到社交网络的内容分发, 从新闻推荐到电商网站的“猜你喜欢”, 机器学习技术已经被广泛应用于我们生活的方方面面, 它正在不断地改变和重塑着人类的社

会生活。随着数据的不断涌现，算法的不断改进以及计算能力的不断提升，诸如图片中的目标识别、语音到文字的转换等极具挑战的问题也正在一项项被攻破。其中最为前卫和火热的技术就是深度学习技术。

深度学习是机器学习的一部分内容，其主要为更抽象和高级的数据进行建模和表达。它具有更强大的能力和灵活性，可以将大千世界表示为嵌套的层次概念体系。越来越多的智能系统正在从基于规则的系统逐步转向深度学习系统上，如图3-2。




图 3-2 智能系统的演变^[31]

Figure 3-2 The Evolution of Intelligent Systems

接下来，本文将对深度学习的一些基本概念和方法进行介绍，包括神经网络、反向传播机制、循环神经网络（RNN）、长短期记忆网络（LSTM）、双向循环神经网络（Bi-RNN）和注意力机制（Attention）。

3.2.2.2 神经网络

神经网络（Neural Network）是深度学习的基础，它是一种计算模型，其灵感来源于人脑的生物神经网络处理信息的方式，如图3-3(1)。我们知道大脑的基本计算单元是神经元，人类的神经系统中大约有 860 亿个神经元以及与之相连的 10^{10} 至 10^{15} 个突触。计算机科学家将神经元的工作原理抽象成为数学的表达形式，如图3-3(2)。


图 3-3 生物神经元及其数学抽象^[31]

Figure 3-3 Biological Neurons And Mathematical Representation

简单来说，神经网络中的基本计算单元是神经元（Cell），也被叫做节点（Node）或单元（Unit）。它接收来自其他的节点或者外部数据源的输入，经过计算之后得到输出。每个输入 x_i 都会有一个对应的权重 w_i ，通过 $\sum_i w_i x_i$ 计算加权和之后再加上一个偏置 b (bias)。最后通过激活函数 f 得到输出 $f(\sum_i w_i x_i + b)$ 。

其中，激活函数 f 是非线性函数，通过引入非线性的激活函数来模拟当细胞接受到的信号总和超过某个阈值时产生激活。我们常常会使用三种激活函数，分别为 *softmax*、*tanh* 和 *ReLU*，如公式3-1和图3-4(图中从左到右分别为 *softmax*、*tanh* 和 *ReLU* 函数)所示。

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (3-1)$$

$$\text{tanh}(x) = \frac{2}{1 + e^{-2x}} - 1 \quad (3-2)$$

$$\text{ReLU}(x) = \max(0, x) \quad (3-3)$$

为了处理更大的数据量，我们一般将许多的神经元组合在一起并分为不同的层 (layer)，从而构成神经网络的基础架构，如图3-5所示。其中主要包含三种层：




图 3-4 激活函数

Figure 3-4 Activation Function

- 输入层 (input layer): 输入层接收由外部输入的数据并传递给下一层, 不进行任何的计算。
- 隐藏层 (hidden layer): 隐藏层进行数据处理和计算, 将计算结果传递给下一层。在网络中可以存在多个隐藏层, 其节点个数也可能不一致。
- 输出层 (output layer): 输出层往往会将结果映射到所需的输出格式上, 例如采用 *softmax* 函数进行多分类。




图 3-5 神经网络的基础架构

Figure 3-5 The Basic Infrastructure of Neural Network

3.2.2.3 反向传播机制

反向传播 (Backward Propagation) 机制^[32] 是训练神经网络的几种方式之一, 使用它可以利用训练数据来进行监督学习。简单来说, 反向传播就是“从错误中学习”, 每当计算结果与正确结果不一致时, 反向传播机制可以有效地纠正神经网络。从图3-6可以看出, 首先经过前向传播得到模型的输出与正确结果之间的总误差 E_{total} , 然后使用链式法则将误差向后传播并得到所有向量和权重的更新梯度。




图 3-6 反向传播机制

Figure 3-6 Back Propagation Mechanism

3.2.2.4 循环神经网络

深度学习领域有两个非常经典和实用的网络，一个是卷积神经网络（CNN），另一个则是循环神经网络（RNN）^[31]。与 CNN 不同的是，RNN 是一种序列模型，例如把一个英文自然语言句子作为输入时，RNN 会按照单词在句子中的顺序单独输入给网络，每次的输出都取决于之前网络计算的结果。经典的循环神经网络如图3-7所示。其中：

- x_t 代表 t 时刻的输入。例如， x_0 表示输入句子中第一个单词的 One-hot 编码向量。
- s_t 代表 t 时刻隐藏层的状态，是网络的“记忆”。 s_t 通过上一时刻的隐藏状态和当前时刻的输入经过 $s_t = f(Ux_t + Ws_{t-1})$ 计算得到。其中 f 为激活函数， s_{-1} 初始化为零。
- o_t 代表 t 时刻的输出。例如，我们想要预测出句子中下一个单词是什么，则 o_t 就是一个概率向量 $o_t = \text{softmax}(Vs_t)$ 来表示词汇表中每个单词出现的概率。

3.2.2.5 长短期记忆网络

经典的循环神经网络有一个明显的缺点，就是当时刻变得很长时，网络无法利用到很早之前的上下文信息。为了解决这个问题，Hochreiter 和 Schmidhuber 发明了一种能够进行长期“记忆”的网络，长短期记忆网络（LSTM）^[31]。如图3-8所示（黄色矩形表示神经网络层；粉色圆形表示运算操作，如加、减、乘、除；黑色单箭头表示向量的传




图 3-7 循环神经网络

Figure 3-7 Recurrent Neural Network

输；合成箭头表示向量的连接；分箭头表示向量的复制），LSTM 的结构与 RNN 保持一致，只是在隐藏层内部做了很多的“记忆”操作，包括：

- 遗忘门（forget gate），目的为从细胞状态中丢弃信息，表示为 f_t 。
- 更新门（update gate），目的为让新的信息加入到细胞状态中，表示为 i_t 、 \tilde{C}_t 和 C_t 。
- 输出门（output gate），目的为确定输出的值，表示为 o_t 和 h_t 。




图 3-8 长短期记忆网络（LSTM）

Figure 3-8 Long Short-Term Memory

3.2.2.6 双向循环神经网络

包括 RNN、LSTM、GRU 在内的很多网络都有一个共同的缺陷就是网络只会对之前时刻的信息进行学习。而实际上，在很多场景下我们需要从未来时刻的信息中学习。双向循环神经网络（Bi-RNN）及其变种的出现就是为了解决这个问题。

Bi-RNN 的结构如图3-9所示，其中的重复模块可以是经典的 RNN、LSTM 或 GRU。网络可以分为两个部分的连接，先是从前向后执行学习到以前的信息，再由后向前在未来的表示中学习。




图 3-9 双向循环神经网络 (Bi-RNN)

Figure 3-9 Bidirectional Recurrent Neural Network

3.2.2.7 注意力机制

传统的序列到序列的网络结构将原句子编码为固定长度的向量再输入给解码器，这将导致大量的信息丢失。为了解决这个问题，谷歌提出了名为注意力机制（Attention）的解决方案。

图3-10中左侧为注意力机制原理。其中， y 表示在翻译过程中解码器生成的单词， x 表示输入的原句子。每个解码器输出的 y_t 现在不单是取决于网络上一时刻的状态，而是取决于它和输入的加权组合。 a 为权重，表示输出时应当考虑多少输入状态。例如，若 $a_{3,2}$ 是一个很大的数字，表示网络认为输出的第三个单词、与输入的第二个单词的关联度很高。图3-10中右侧为注意力机制的可视化展示，使得我们能够解释模型的一些内部原理。例如，将法语翻译为英语时网络将“la Syrie”翻译为“Syria”，可视化结果表明模型在此刻将两个单词关联到一个单词上而不是一一对应。

3.2.2.8 强化学习

机器学习可以分为三种学习类型，分别为非监督学习、监督学习和强化学习。强化学习是主要依靠智能体在环境（environment）中不断地试错并采取一系列的行为（action）




图 3-10 注意力机制原理及可视化

Figure 3-10 Attention Mechanism And Visualization

从而累积得到最大的奖励（reward）的过程，其范式（如图3-11所示）类似于人类学习知识的过程。一般来说，强化学习由智能体和环境两个部件组成，主要有以下四个要素：状态（state）、动作（action）、智能体（agent）和奖励（reward）。

从算法的角度，强化学习可以分为三类：

- 基于策略（Policy based）的强化学习。其目标为找到最优的策略。
- 基于价值（Value based）的强化学习。其目标为奖励综合的最大化。
- 基于动作（Action based）的强化学习。其目标为最优动作的执行。




图 3-11 强化学习范式

Figure 3-11 The Paradigm of Reinforcement Learning

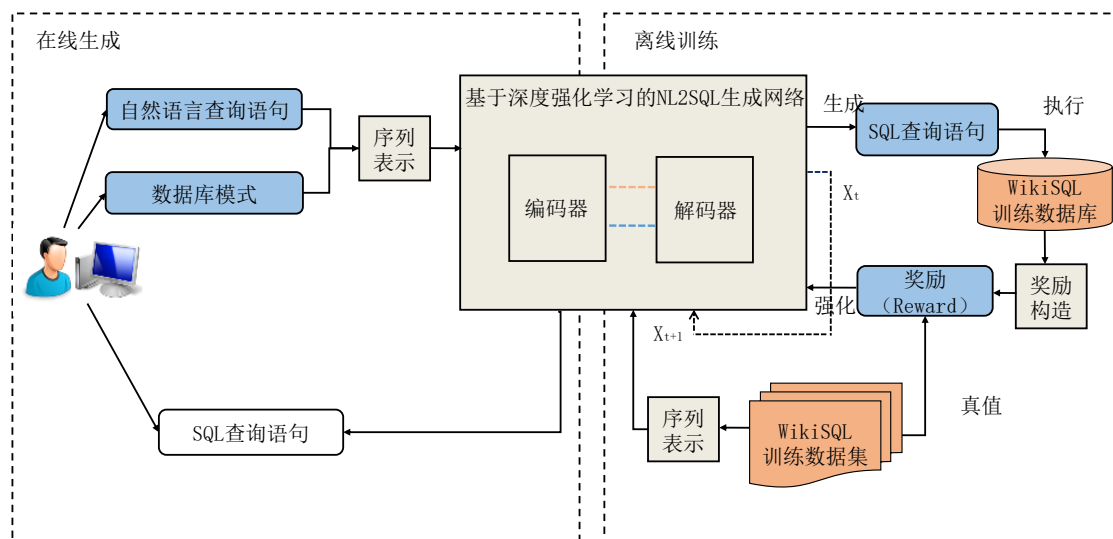


图 3-12 基于深度强化学习的 NL2SQL 生成的技术方案

Figure 3-12 The Approach of NL2SQL with Deep Reinforcement Learning

3.3 解决方案

本文研究提出了一种基于深度强化学习的 NL2SQL 生成方法，如图3-12所示，它包含离线训练和在线生成两部分。

在离线训练中，本文从 WikiSQL 数据集中获取自然语言查询语句及其对应的数据库模式数据并进行序列的向量编码表示 (Embedding)，基于深度强化学习的 NL2SQL 生成网络 (称为增强解析器) 使用这些序列表示作为输入并输出一条 SQL 查询语句，将该语句导入数据库进行执行后得到执行结果并交由奖励函数进行计算，得到奖励后对原网络进行强化。增强解析器由编码器 (Encoder) 和解码器 (Decoder) 组成，是基于时间序列的模型。

在在线生成中，用户可以输入自然语言查询语句以及其对应的数据库模式，系统将对输入序列进行向量编码表示，增强解析器将生成并返回给用户一条 SQL 查询语句。

3.3.1 增强解析器模型

针对输入 x 来生成结构化的输出 y 的过程可以被分解成为一系列的语义解析决策的过程。本文参考强化学习的基本范式，将增强解析器模型的基本过程定义为：

解析器 (agent) 从初始状态启动并不断根据学习的策略采取不同的动作 (action)。

每个动作都会将解析器从一个状态 (*state*) 转移为另一个状态, 直到解析器到达它的最终状态并停止。在解析器的最终状态下, 得到输出 y 。

在这里, 本文采取一种概率的方法来对整个策略 (*policy*) 进行建模。通过对输入 x 产生的所有动作 (*action*) 和解码器产生的历史行为建模得到一个概率分布。而增量解析器的训练目标就转换为了如何去优化一个参数化的策略的问题, 如公式3-4所示。

$$P_{\theta}(y|x) = P_{\theta}(\mathbf{a}|x), \quad \theta \text{ 为模型参数} \quad (3-4)$$

在公式3-4中, θ 为模型参数, 通过执行动作 (*action*) 序列 $\mathbf{a} = \{a_1, a_2, \dots, a_k\}$, 解析器将被不断引导并从初始状态转换为包含输出 y 的最终状态。在此, 本文需要假设每个输出 y 有且仅有一个对应的动作序列 \mathbf{a} (详见3.3.4节内容)。行动序列的概率 $P_{\theta}(\mathbf{a}|x)$ 可展开为增量策略概率的乘积 (公式3-5):

$$P_{\theta}(\mathbf{a}|x) = \prod_{i=1}^k P_{\theta}(a_i|x, a_{<i}), \quad |\mathbf{a}| = k \quad (3-5)$$

在在线生成期间, 本文的模型并非尝试枚举整个输出空间并找到最高的得分 $\mathbf{a}^* = \arg \max_{\mathbf{a}} P_{\theta}(\mathbf{a}|x)$, 而是在解码器中采用了一种贪心的方法: 在每一步都根据策略 (*policy*) 来选择得分最高的行动, 即 $a_i^* = \arg \max_{a_i} P_{\theta}(a_i|x, a_{<i}^*)$ 。

在后面的几小节中, 将给出增强解析器的状态 (*state*) 的定义与动作 (*action*) 序列, 还会详细说明整个基于编码器-解码器神经网络体系结构的增强解析器模型。

3.3.2 状态与动作序列

对应于图3-1中示例在完全解析之后, 可结构化表示为:

$$\left[\begin{array}{cc} \text{AGG} & \text{NONE} \\ \text{SELCOL} & \text{Height(ft)} \\ \text{COND} & \left\langle \left[\begin{array}{cc} \text{COL} & \text{Name} \\ \text{OP} & = \\ \text{VAL} & \text{WillisTower} \end{array} \right], \left[\begin{array}{cc} \text{COL} & \text{Location} \\ \text{OP} & = \\ \text{VAL} & \text{Chicago} \end{array} \right] \right\rangle \end{array} \right]$$

因此, 解析器的中间状态就被这样表示, 其中一些尚未填充的特征值表示为 ϵ 。

$$\text{解析器的初始状态 } p_0 \text{ 的值为空和空列表, 表示为 } \left[\begin{array}{cc} \text{AGG} & \epsilon \\ \text{SELCOL} & \epsilon \\ \text{COND} & \langle \rangle \end{array} \right]。$$

除此之外, 还需要定义动作 (*action*) 清单。每个动作可以将解析器的状态从一个状

态转换为另一个状态，即 $p \rightarrow p'$ 。设 $p = \begin{bmatrix} AGG & agg \\ SELCOL & selcol \\ COND & cond \end{bmatrix}$ ，并且在表3-1中给出每个动作执行后的转移状态 p' 。

表 3-1 动作 (action) 清单

Table 3-1 The Inventory of Actions

动作 (action)	由状态 p 执行该动作之后的状态	参数表示
$AGG(agg)$	$p[AGG \mapsto agg]$	-
$SELCOL(c_i)$	$p[SELCOL \mapsto c_i]$	r_i^C
$CONDCOL(c_i)$	$p[COND \mapsto p.COND \begin{bmatrix} COL & c_i \\ OP & \epsilon \\ VAL & \epsilon \end{bmatrix}]$	r_i^C
$CONDOP(op)$	$p[COND_{-1} \mapsto p.COND_{-1}[OP \mapsto op]]$	-
$CONDVAL(w_{i:j})$	$p[COND_{-1} \mapsto p.COND_{-1}[VAL \mapsto w_{i:j}]]$	$r_i^W \text{ and } r_j^W$
END	$p(\text{最终状态})$	-

在表3-1中，解码器中所使用的参数表示将在3.3.3节中进行解释。 $p[AGG \mapsto agg]$ 表示与状态 p 处于同一状态，不过其特征值 AGG 已经被赋值为 agg 。 $||$ 表示列表展开， $COND_{-1}$ 表示在列表中的上一个元素。需要特别解释的是，动作 $CONDVAL$ 会从输入问句 w 中选择所需的文字段 $w_{i:j}$ 。但这样做会导致一个问题，它将产生大量的动作，其数量级为问题长度的二次方。因此，本文将动作 $CONDVAL$ 分解为两个连续的子动作，一个去选择起始位置 w_i ，另一个则选择终止位置 w_j 。在动作序列的最后，还需要增加一个 END 动作来执行解析过程并使解析器进入结束状态。例如，图3-1中的例子可以看作是如下的一个动作序列：

1. $AGG(NONE)$
2. $SELCOL(c_3)$
3. $CONDCOL(c_1)$
4. $CONDOP(=)$
5. $CONDVAL(w_{5:6})$
6. $CONDCOL(c_2)$
7. $CONDOP(=)$
8. $CONDVAL(w_{8:8})$

9. END

需要注意的是该节中的定义是基于所有有效序列都具有 AGG SELCOL (CONDCOL CONDOP CONDVAL)* END 形式的假设之上。这样的假设能够保证可以从所有的最终状态输出中提取出完整的逻辑形式出来。对于其他不同结构的 SQL 语句来说, 还需要重新设计动作的清单以及解析器的状态。

3.3.3 编码器与解码器




图 3-13 基于深度强化学习的 NL2SQL 生成网络

Figure 3-13 The Network of NL2SQL using Deep Reinforcement Learning

增强解析器的网络结构如图3-13所示, 包含编码器和解码器两个部分。

编码器的具体步骤设计如下:

1. 对于输入的句子 w 中的每个单词 w_i , 先将其使用词向量进行向量编码 (word embedding)。

2. 将其送入一个双向的长短期记忆网络 (bi-directional Long Short-Term Memory, 简称 bi-LSTM), 其中每个细胞 (cell) 会有一个隐状态 h_i^W 。
3. 由于一个列名可能由一个或多个单词构成, 对每个列名先进行词向量编码并输入一个 bi-LSTM 中, 再使用从 bi-LSTM 中得到的最终的隐状态作为列名初始表示 (initial representation)。
4. 使用自注意力机制 (self-attention^[33]) 将该初始表示转换为 h_j^C 。
5. 在得到 h_i^W 和 h_j^C 之后, 使用缩放点积注意力^[33] 得到 h_j^C 和 h_i^W 的加权平均值并作为单词 w_i 和 c_j 的向量表示。
6. 将这两个向量进行拼接并分别送入使用自然语言问题和列名作为输入的 bi-LSTM 中。这两个 LSTM 网络的隐状态就是所期望的向量表示 r_i^W 和 r_j^C 。

解码器的目标是为了对由输入 x 和历史动作 $a_{<i}$ 构成的概率分布 $P_\theta(a|x, a_{<i})$ 进行建模, 其主要面临以下两个挑战:

1. 动作 (action) 的不确定性: 模型采取的动作都是取决于输入以及当前解析器的状态, 而不是固定不变的。
2. 增强解析器的决策完全依赖于其获得的上下文信息: 增强解析器依赖于解码的历史信息以及输入的问题和列名信息。

为了解决第一个挑战, 本文使用了基于 LSTM 的解码器架构并使用独立打分机制来对动作的可能性进行打分。模型给每个候选的动作 a 打上分数 s_a 并且使用 *softmax* 函数将分数正则化 (normalize) 到一个概率分布上。对于 i 时刻来说, 使用 h_i^{DEC} 来表示当前解码器的隐状态并且使用双线性函数 $s_a = (h_i^{DEC})^T U^A r_a^A$ 来给分数 a 建模。双线性函数中 r_a^A 是由动作嵌入 (action embedding) 和参数表示 (parameter representation) 建模得到的动作 a 的向量表示。其中参数表示已经在表3-1中给出。

为了解决第二个挑战, 本文使用点积注意力机制 (dot-product attention)^[33] 来捕获模型决策与输入的问题和列名之间的依赖关系。之后, 将前一 i 时刻的输出动作表示 $r_{a_i}^A$ 、自然语言问句的注意力向量 e_i^W 以及列名的注意力向量 e_i^C 拼接在一起, 作为 $i+1$ 时刻的 LSTM 解码器的第一层的输入。其中, 向量 $e_i^C = \sum_j \alpha_{i,j} r_j^C$, $\alpha \propto h_i^{DEC} \cdot r_j^C$ 。向量 e_i^W 的定义相似可得。

3.3.4 过滤条件顺序问题和隐式列名问题

前文所述的工作都是基于一个假设, 即每个自然语言问题都只会对应一条 SQL 查询语句, 并且每个查询语句都只会对应一个正确的动作序列。然而实际上, 这个假设并不能完全成立。一个简单的例子就是出现在 **WHERE** 子句里面的过滤条件的顺序并不确定, 不同的过滤条件的顺序将会导致不同的动作序列。除此之外, 本文在3.3.4.2节中还

对过滤条件顺序问题进行了描述，它会产生一个自然语言问题可以转换为多种 SQL 查询语句且其执行结果仍保持一致的“歧义”问题。对于最终用户而言，这些查询语句其实是完全等效的。

针对上述的两种情况，本文将每个训练样本转换为多个序列以供参考并且在训练过程中使用多种目标策略。参考语法分析领域的办法，本文采用一个非确定的预言 (oracle) 从而使得解析器可以在多个动作序列中进行探索。特别注意的是，在前文中所述的训练机制都是采用基于静态预言而非非确定预言的。

本文假定预言 (oracle) O 可在时刻 t 返回一组正确且连续的动作 $O(x, a_{<t})$ 。其中，将 $O(x, a_{<t})$ 集合中的任何一个对象拿出来执行解析都可以得到最后的正确结果。对于每一个训练样本 L_x 来说，其训练目标将被如公式3-6定义。

$$L_x = \sum_{i=0}^k \log \sum_{a \in O(x, a_{<i})} P_{\theta}(a|x, a_{<i}) \quad (3-6)$$

其中 $a_{<i}$ 表示动作序列 a_1, \dots, a_{i-1} ， $a_i = \arg \max_{a \in O(x, a_{<i})} a_i$ 代表在训练时解析器判定的置信度最高的动作。

当 O 是静态预言时，其只会包含一个单独且正确的动作，公式3-6可被化简为一个简单的交叉熵的损失函数。而当 O 是非确定的预言时，在训练期间，解析器会对多个不同的但是同样是正确的动作序列进行解析而不再是一个唯一的动作序列。

3.3.4.1 解决过滤条件顺序问题

训练一个形如 text-to-SQL 的解析器往往会碰到过滤条件顺序的问题。在 SQL 查询语句中，过滤条件的先后顺序不会对语句的意图和执行结果产生影响。但是在增强解析器模型中，我们需要将查询语句固定下来然后依据预定义的格式执行。预测出的与训练集真值 (groundtruth) 的标签不同但是完全正确的语句可能没有办法得到适当的奖励 (reward)。

有一些前人的研究使用了增强学习^[6] 或模块化的序列集成^[8] 的方案来解决过滤条件顺序的问题。其中，前者在一定程度上解决了这个问题但明显降低了模型的优化稳定性并导致训练时间大大增加。而后者采用了一种较为复杂的模型设计来捕获子句之间的相互依赖关系，其预测出的过滤条件的信息将被用于预测下一个过滤条件。

本文利用一个非确定性的预言来解决过滤条件的顺序问题。将之前的模型通过结合增量式方法的优势，利用子句之间的相互依赖性和模块化的方法来获得更高质量的训练信号。具体来说，在预测下一个过滤条件的几个步骤中，模型会接受所有可能的后续条件（即尚未预测出的过滤条件）而忽视其位置所在。对于图3-1中给出的示例，除了本

文在3.3.2节中给出的转换序列之外，本文提出的非确定性的预言也接收 $CONDCOL(c_2)$ 作为第二个动作的正确的延续。如果模型即将预测出第一个动作，那么它将在预测第一个动作之前继续去预测第二个过滤条件是什么。

3.3.4.2 解决隐式列名问题

在模型的初步验证实验过程中，本文观察到解析器模型在开发集上会产生一些错误的预测，其主要的出错原因是隐式列名的问题。在很多场景下，自然语言的问题中并没有明确提到过滤条件中所需要的列名。例如：在图3-1中的问题中就没有直接提到“Name”这个列名。同样地，“What is the area of Canada?”这个典型的自然语言问题中也没有出现关键词“country”。对于我们人类而言，这种隐式的表达会使得自然语言的问题更加简洁，可以很快地从上下文的相关内容中轻易地推断出缺失的信息。但是对于机器学习的模型来说，这些都会是巨大的挑战。

本文结合非确定性的预言及动作清单中的 $ANYCOL$ 来解决隐式列名的问题。在模型运行过程中，本文将根据过滤条件来拓展预测，从而模拟人类如何轻松找到未在问题中出现的列名的过程。在图3-1中的例子中，除了动作 $CONDCOL(c_1)$ 外，还允许模型进行另一种的动作 $CONDCOL(ANYCOL)$ 。当 $CONDCOL(ANYCOL)$ 出现时，例如此时的 $ANYCOL = 'WillisTower'$ ，本文会将它拓展为 $Rank = 'WillisTower' OR Name = 'WillisTower' OR ...$ 。这样一来，当列名没法被明确地解析出来时，非确定预言可以接收 $ANYCOL$ 作为列名并且让模型去预测哪种形式更容易被学习。

3.4 实验与分析

为了评估基于深度强化学习的 NL2SQL 方法的准确度，本文采用 WikiSQL、ATIS 和 Spider 数据集进行了对比实验。

3.4.1 数据集与评价指标

WikiSQL 是由 Zhong^[6] 提出的第一个由自然语言问题、对应的 SQL 查询语句及数据表 schema 构成的大型数据集。WikiSQL 虽然在 SQL 语法上的覆盖范围比之前的数据集（例如，ATIS^[34, 35] 和 GeoQuery^[36]）要弱，但是在问题、数据表模式和内容上具有很高的多样性。这也使其在近期吸引了大量的研究人员的关注并使用神经网络进行建模和评估^[6-9, 28-30]。

图3-1为 WikiSQL 数据集^[6] 中的一个样例。WikiSQL 数据集是纯自然语言生成 SQL 查询语句的第一个数据集。其中包含 80654 组自然语言问句及其对应的 SQL 查询语句，




图 3-14 WikiSQL 数据集中的问题类型分布

Figure 3-14 Distribution of Questions in WikiSQL




图 3-15 WikiSQL 数据集中问题、查询和表的分布

Figure 3-15 Distribution of Table, Question, Query sizes in WikiSQL

涵盖 24241 张从 Wikipedia 中获取的数据表。从图中可以看到, NL2SQL 任务的输入实际包括两部分: 自然语言问题以及一个简单的数据表 schema (schema 代表数据表及表中的列)。图3-14显示了 WikiSQL 数据集中的问题类型分布, 问题的主要类型包括“what”, “which”, “how many”等。图3-15给出了 WikiSQL 数据集中问题、查询和表的数量分布情况。

表 3-2 SQL 查询语句模板

Table 3-2 The Template of SQL Query Statement

*SELECT agg selcol WHERE col op val (AND col op val)**

WikiSQL 数据集中 SQL 查询语句具有一定的约束条件:

- WikiSQL 数据集中表的列名都需要是有意义的自然语言描述, 使得 SQL 生成网络只需要对自然语言问题和列名进行处理。
- 生成的 SQL 查询语句中的所有令牌 (token) 都必须是 SQL 语言的符号或自然语言查询语句的子串。例如, “WHERE name = ‘Bob’” 使用了 Where 子句进行条件约束, 其中的令牌 “Bob” 必须是自然语言查询语句中的子串。
- 必须符合表3-2中的模板, *selcol* 代表表中的列名, *agg* 代表聚合操作 (例如: COUNT, SUM 或空), *WHERE* 后面为由一系列过滤调教构成的子句, 每个 *op* 代表一个过滤操作 (例如: “=”), *val* 代表出现在自然语言问句中的过滤值。值得注意的是, 尽管模板中的过滤条件服从标准的线性顺序, 但由于存在 *AND* 符号, 所以过滤条件的先后顺序是无关紧要的。

除了在 WikiSQL 进行实验外, 本文还在 ATIS^[35] 和 Spider 数据集^[37] 上进行了补充实验, 以评估模型的拓展性和生成不同难度的 SQL 查询语句的能力。

本实验将数据集划分为训练集、验证集和测试集。评价指标包括逻辑形式准确度和执行结果准确度。设 N 为数据集中所有测试样本的总数, N_{lf} 表示生成的 SQL 语句与真值 (groundTruth) 在形式上完全匹配的数量, N_{ex} 表示生成的 SQL 语句与真值执行结果一致的数量。逻辑形式准确度为 $Acc_{ex} = \frac{N_{ex}}{N}$, 执行结果准确度为 $Acc_{lf} = \frac{N_{lf}}{N}$ 。举例来说, “SELECT COUNT(name) WHERE SSN = 123” 语句与 “SELECT COUNT(SSN) WHERE SSN = 123” 语句的逻辑形式不一样但执行结果却是一样的, 则有 $Acc_{lf} = 0$, $Acc_{ex} = 1$ 。本节将使用两种准确度指标作为实验的评价指标。

3.4.2 数据预处理与模型参数设置

在数据预处理过程中, 本文借鉴了^[38]的方法对数据进行处理。在词嵌入层 (embedding layer) 在训练集中出现至少两次的单词才会被保留在词汇表 (vocabulary) 中, 剩下的将被赋予特殊的输入单元 “UNK”。本文使用已经训练好的 Glove 词嵌入^[39], 使得模型在训练时对词嵌入进行继续训练, 该词嵌入的维度为 16 维。本文还使用^[9]的方法对自然语言问题和列名进行了类型嵌入 (type embedding): 对于每一个单词 w_i 和 c_j , 本文会判断其是否出现在列名中并给出一个离散的表示, 而这些特征会被嵌入为 4 维的向量表示。类型嵌入将会和词嵌入连接在一起并作为双向 LSTM 网络的输入。

另外, 还需要说明的是, 编码阶段的双向 LSTM 的单隐藏层的大小为 256 维, 其中单向为 128 维。解码阶段的 LSTM 由大小各为 256 的两个隐藏层组成。所有的注意力连接都采用 3.3.3 节中描述的点积形式。

在训练阶段, 本文设置批尺寸 (batch size) 为 64 并使用 0.3 的丢失率 (dropout rate) 进行正则化处理。同时, 本文使用了 ADAM 优化器^[40]、设置初始学习率为默认值 0.001 用于参数的更新迭代以及将梯度修剪到 5.0 用于保证训练的稳定。

3.4.3 实验结果与分析

3.4.3.1 WIKISQL 实验结果与分析

表 3-3 WikiSQL 中验证集和测试集的准确度

Table 3-3 The Accuracy of Validation Sets and Test Sets in WikiSQL

模型	验证集		测试集	
	Acc_{lf}	Acc_{ex}	Acc_{lf}	Acc_{ex}
TypeSQL 模型 (引用)	72.5	79.0	71.7	78.5
SQLNet 模型 (引用)	76.1	82.0	75.4	81.4
本文提出的模型				
增强解析器 (静态预言)	76.1	82.5	75.5	81.6
增强解析器 (非确定性预言, 不解决过滤条件顺序问题)	75.4	82.2	75.1	81.8
增强解析器 (非确定性预言)	49.9	84.0	49.9	83.7
增强解析器 (非确定性预言) + EG (5)	51.3	87.2	51.1	87.1

WIKISQL 实验的主要结果如表 3-3 所示。其中 Acc_{lf} 表示逻辑形式准确度, Acc_{ex} 表示执行准确度, “+ EG (5)” 表示使用执行引导策略且集束大小为 5。

可以看到增强解析器模型在使用静态预言的情况下就可以达到目前该领域的最高水平^[38] 的范围。在此基础之上, 使用了非确定性预言的增强解析器在执行准确度上还可以大幅度提升 2.1%, 但是其逻辑形式准确度反而会有所下降, 主要原因是使用了 *ANYCOL* 进行列的选择时, 生成的 SQL 查询语句和真值 (groundtruth) 不能完全匹配。本文还对过滤条件顺序问题和非确定性预言中的 *ANYCOL* 的贡献度进行了实验对比。当非确定性预言只用来解决 3.3.4.1 节中的过滤条件顺序问题时, 模型的性能和使用静态预言的模型大致相同。这是因为在训练集中所出现的过滤条件的序列变化已经足够丰富, 序列到动作的模型已经可以学习的很好。除此之外, 在预言中增加 *ANYCOL* 可以更好地捕捉到隐式的列明并提升性能, 使得执行准确度从 81.3% 增加至 83.7%。

增强解析器模型在解码阶段使用的是贪心策略, 即选择通过策略预测出的获得最高得分的动作。除此之外, 还可以使用集束搜索 (beam search) 来进行搜索。其中, 集束搜索是一种启发式的图搜索算法, 为了减小搜索的空间与时间, 在向图进行深度扩展时, 去裁剪掉一些质量较差的节点, 保留一些质量较高的节点。使用集束搜索意味着可以在更大的搜索空间中进行搜索。另外, 本文还将执行引导策略和集束搜索策略结合在一起, 进行执行引导的解码器可以避免生成语义错误的 SQL 查询语句, 例如会产生运行时错误 (runtime error) 和空结果 (empty result) 错误的 SQL 查询语句。除此之外有一点很关键, 那就是将生成出的部分的输出放到数据库中的执行, 得到的执行结果可以用来指导解码过程。解码器可以维持一种部分输出的状态, 该状态由聚合操作、选择列操作和完整的过滤条件构成。在每个动作执行之后, 由执行引导策略引导的解码器将保留前 K 个得分最高的且没有运行错误的 SQL 查询语句, 在结束状态时从这 K 个语句中选出最有可能的那个查询语句。在 $K=5$ 时, 模型在执行引导策略下载测试机上实现了 87.1% 的执行准确度。

表 3-4 使用不同集束大小的模型性能

Table 3-4 Model Performance with Different Beam Sizes

预言类型	w/o EG	+ EG (1)	+ EG (3)	+ EG (5)
静态	81.6	83.5	86.4	86.7
非确定	83.7	86.0	87.1	87.1
运行速度 (每秒运行的样本数)	48.3	30.1	8.2	4.4

表3-4给出了具有执行引导过程的解码器在静态预言下的模型性能。其中“+ EG (k)”的含义同表3-3, k 为集束大小。其性能与非确定性预言下模型的性能非常接近, 但需要更大的集束, 也就意味着其解码的时间会大大增加。

3.4.3.2 ATIS 实验结果与分析

为了评估本文的模型是否可以推广到其他的数据集上，本文还使用了 ATIS 数据集进行了实验，数据在表3-5中给出。ATIS 数据集包含更多样的 SQL 结构，包括对多个表的查询以及嵌套查询。为了和本文的任务设置相兼容，在数据处理时仅保留了 ATIS 数据集中没有嵌套查询的样本，即仅包含 AND 操作不包含 INNER JOIN 操作符。本文把多个相关的表进行 JOIN 连接并构造成单独的一个数据表以便模型进行输入。经过简化之后数据集共包含 933 个样本并分布在训练集、验证集和测试集中，并分别有 714、93 和 126 个样本。

表 3-5 ATIS 数据集上的实验结果

Table 3-5 The Experimental Results on the ATIS Dataset

模型	验证集		测试集	
	Acc_{lf}	Acc_{ex}	Acc_{lf}	Acc_{ex}
增强解析器（静态预言）	87.1	88.2	65.9	67.5
增强解析器（非确定性预言, 不解决过滤条件顺序问题）	88.1	89.2	68.3	69.1

本文使用静态预言和不使用 *ANYCOL* 的非确定预言的模型进行训练，在测试集上分别达到了 67.5% 和 69.1% 的准确度。使用非确定预言的模型在性能上有大幅增强，这也验证了本文之前的假设：与 WikiSQL 相比而言，ATIS 是一个小得多的数据集，因此可以解决过滤条件顺序问题的模型的效果会有不小提升。另外，需要说明的是，由于 ATIS 数据的性质，没有对 *ANYCOL* 进行测试。

3.4.3.3 Spider 实验结果与分析

Spider 数据集是一个由 11 名耶鲁大学学生标注的大型的跨域的包含语义解析和文本到 SQL 语句的数据集。其挑战的目标为开发在跨域的数据集上开发自然语言接口。Spider 数据集由 200 个数据库中的 10181 个问题和 5693 个 SQL 查询语句组成，并且其中有很多表覆盖了 138 个不同的域。不同复杂程度的 SQL 查询会出现在训练集和测试集中，如图3-16中所示。这也就要求模型需要具有较好的拓展性，从而适应新的 SQL 查询语句以及新的数据库模式。

如图3-17所示，Spider 数据集的 1.0 版本有别于其他之前的所有 SQL 语义解析的数据集：

- 对于 ATIS, Geo 和 Academic 数据集来说，每个数据集都只包含在一个数据库

Easy*What is the number of cars with more than 4 cylinders?*

```
SELECT COUNT(*)
FROM cars_data
WHERE cylinders > 4
```

Hard*Which countries in Europe have at least 3 car manufacturers?*

```
SELECT T1.country_name
FROM countries AS T1 JOIN continents
AS T2 ON T1.continent = T2.cont_id
JOIN car_makers AS T3 ON
T1.country_id = T3.country
WHERE T2.continent = 'Europe'
GROUP BY T1.country_name
HAVING COUNT(*) >= 3
```

Meidum*For each stadium, how many concerts are there?*

```
SELECT T2.name, COUNT(*)
FROM concert AS T1 JOIN stadium AS T2
ON T1.stadium_id = T2.stadium_id
GROUP BY T1.stadium_id
```

Extra Hard*What is the average life expectancy in the countries where English is not the official language?*

```
SELECT AVG(life_expectancy)
FROM country
WHERE name NOT IN
(SELECT T1.name
FROM country AS T1 JOIN
country_language AS T2
ON T1.code = T2.country_code
WHERE T2.language = "English"
AND T2.is_official = "T")
```

图 3-16 Spider 数据集样例

Figure 3-16 Examples of the Spider Dataset

中执行的若干个 SQL 查询，并且 SQL 查询在训练集和测试集的分割时完全相同的。

- WikiSQL 数据集中的 SQL 查询和表的数量都相对较大，但是所有的 SQL 查询语句都较为简单，并且每个数据库都只有一个没有任何外键的表。

所以，在 Spider 数据集上的实验能够说明模型从简单的 SQL 查询语句生成到复杂的 SQL 查询语句生成的能力，说明模型的通用性与泛化性。

从表3-6可以看出，本文使用 ANYCOL 的非确定预言的模型进行测试，在测试集上分别达到了 23.2% 和 24.1% 的准确度，超过了之前提出的所有方法。使用非确定预言的模型可以很好地解决过滤条件顺序问题，所以在性能上表现优异。同时，得益于 ANYCOL 机制对隐式列名问题的处理，在 Spider 数据集上的表现证明了模型具有很好的泛化性能。




图 3-17 Spider 数据集的组成

Figure 3-17 The Components of The Spider Dataset

表 3-6 Spider 数据集上的实验结果

Table 3-6 The Experimental Results On The Spider Dataset

模型	验证集	测试集
Seq2Seq + attention	1.8	4.8
TypeSQL	8.0	8.2
SQLNet	10.9	12.4
SyntaxSQLNet	18.9	19.7
增强解析器（非确定性预言）+ EG (5)	23.2	24.1

3.5 本章小结

本章提出了一种基于深度强化学习的 NL2SQL 生成的方法。在离线训练阶段，将符合 WikiSQL 格式的数据进行序列表示后输入给网络模型，模型生成 SQL 查询语句后在数据库中执行，再使用奖励函数构造奖励用于强化网络模型。

在在线生成阶段用户输入自然语言查询语句及数据库模式，训练好的网络模型将生成符合用户查询意图的 SQL 查询语句。本文把其中最重要的网络模型称为“增强解析器”模型，它由编码器和解码器构成并结合了自注意力机制。参考强化学习的基本范式，本章将增强解析器学习的目标转换为策略的优化问题并对解析器的状态和动作进行了定义。为了解决 SQL 查询语句中的过滤条件的顺序问题以及隐式列名的问题，本章还提出了非确定性预言和 *ANYCOL* 状态的解决办法。最后，本章与目前 NL2SQL 领域的前沿方法进行对比，在不同数据集上的实验结果证明了本文方法的有效性。

第四章 基于多任务学习的 NL2SQL 生成

在第三章中，本文结合了深度学习与深度强化学习来解决 NL2SQL 的问题。然而，目前所有研究都只是将英文的自然语言问题转换为机器可执行的 SQL 查询语句，而没有涉及到其他语种的自然语言。本章研究提出了基于多任务学习的自然语言生成 SQL 查询语句（NL2SQL）的方法，不仅解决了中文自然语言问题转换为 SQL 查询语句，同时提升了英文自然语言生成 SQL 查询语句的准确性。

4.1 相关技术

4.1.1 注意力转换器模型

2017 年谷歌提出了注意力转换器模型（Transformer）^[33]，其在翻译任务上的表现十分优异。在该模型中，最重要的机制为多头自注意力机制（multi-head self-attention）和位置编码机制（Positional Encoding）。

(1) 多头自注意力机制（multi-head self-attention）




图 4-1 缩放点积注意力（scaled dot-product attention）和多头注意力（multi-head attention）

Figure 4-1 Scaled Dot-product Attention and Multi-head Attention

多头自注意力机制包含缩放点积注意力 (scaled dot-product attention) 和多头注意力 (multi-head attention) 两部分, 如图4-1所示)。在缩放点积注意力中, 输入由 query (Q), d_k 维的 key (K) 以及 d_v 维的 value (V) 组成, 需要将 query 和一些列的 (key, value) 对映射起来, 如公式4-1。实际上, 注意力机制就是一个由诸多 Query 和 (key, value) 组成的映射函数。

$$q \rightarrow [(k_1, v_1), (k_2, v_2), \dots] \rightarrow attention = w_1 * v_1 + w_2 * v_2 + \dots \quad (4-1)$$

query 和所有 key 计算点积, 然后除以 $\sqrt{d_k}$ 并计算 softmax 值, 得到 value 对应的权重 w , 如公式4-2。

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (4-2)$$

而多头注意力实际上就是将 query 和 key 做多次的线性映射, 最后将结果串联在一起。在编码器和解码器结构中, query 来自于上一层的解码器中, 而 key 和 value 来自上一层的编码器中。多头注意力就是将句子中的每一个部分都参与到编码和解码的过程中, 允许模型关注来自不同位置及不同表示的信息, 如公式4-3。

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h) \quad \text{其中 } head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (4-3)$$

(2) 位置编码机制 (Positional Encoding)

鉴于注意力转换器模型并没有 CNN 或 RNN 的结构, 为了引入序列的位置信息, 还需要加入位置编码机制。在编码器和解码器的嵌入之后的向量与 d_{model} 维的位置编码进行求和。位置编码的方式有很多种, 可以是学习得到的也可以是固定的, 可以对不同序列使用 \sin 和 \cos 函数进行计算, 如公式4-4。

$$PE_{(pos, 2i)} = \sin(\frac{pos}{10000^{\frac{2i}{d_{model}}}}) \quad (4-4)$$

$$PE_{(pos, 2i+1)} = \cos(\frac{pos}{10000^{\frac{2i}{d_{model}}}}) \quad (4-5)$$

4.1.2 NLP 领域的迁移学习

在自然语言处理 (NLP) 领域中有很多重要成果都与迁移学习有关。例如 Word2Vec^[41], skip-thought Vec^[42] 和 Glove^[39] 都是先产生预训练好的词向量, 再把这些知识“迁移”到

其他应用上。嵌入 (embedding)^[43, 44]、中间表示 (intermediate representation)^[45] 和语言模型中的权重^[46] 都可以被迁移到其他类似的架构甚至分类任务^[47] 上。从机器翻译模型上得到的中间表示可以迁移并提升处理问答、情感分析等任务的模型^[48]。使用问答数据集训练的模型与使用推理数据集训练的模型可以完成对方的任务^[49]。高质量机器翻译模型与低质量机器翻译模型之间也相互支持^[50]。这些研究表明, 想要同时学习中文自然语言查询转换英文自然语言查询和英文自然语言查询生成 SQL 查询语句两个任务是可以迁移的。

4.1.3 NLP 领域的多任务学习

2011 年, Collobert^[44] 首先提出了可以同时处理多个自然语言问题的解决方案, 处理的问题包括分块 (chunk)、命名实体识别 (NER)、词性标注 (POS)、语义角色标注 (SRE) 等。之后 Hashimoto^[51] 也提出了可以同时处理依赖解析、语义相关和自然语言推理任务的网络结构。使用跨语种的预料进行机器翻译模型训练时发现, 采用多任务学习的方法^[52] 甚至可以一定程度解决零样本的问题。基于序列到序列的模型采用不同数量的编码器和解码器时^[53] 甚至可以同时学习翻译、解析和图像字幕生成的任务。甚至学习图像分类和语音识别任务的模型可以被模块化^[54] 之后拓展到图像到文字的问答任务上^[55]。采用^[56] 的方法还可以减轻任务之间存在的干扰。

事实上, 早在 1997 年 Caruana^[57] 就证明多任务学习是有效的, 因为模型能够利用任务之间的关联性。当同时学习的任务十分相关时, 学习不同的任务可以提供归纳偏差^[58], 强迫模型去学习那些更通用和普遍的表达方法。通过将许多单独的任务同时学习并比较, 可以充分验证多任务学习的有效性^[59-61]。

4.2 解决方案

本文采用 TCR(Task-Content-Result) 模板将多任务进行统一, 并设计了一种基于多任务学习的神经网络结构实现多项任务的同时学习。

4.2.1 TCR 模板

本文中, 中文自然语言问题生成 SQL 查询语句被划分为两个子任务: 中文自然语言翻译为英文自然语言任务和英文自然语言问题生成 SQL 查询语句任务。在第三章中, 本文所提出的基于深度强化学习的解决方案已经可以有效地解决 NL2SQL 问题, 并且在 WikiSQL 数据集和 Spider 数据集上有优异的表现。所以, 本文产生了一个非常自然的想法: 直接使用翻译工具或翻译软件将中文的自然语言问题直接转换为英文自然语言

问题，之后再使用3.3.1节中提出的增强解析器模型将英文自然语言转换为 SQL 查询语句。但是，这种方法会遇到许多问题，如图4-2所示，示例中，中文自然语言均使用谷歌翻译自动翻译为英文自然语言。

示例1:

中文：有多少来自约克大学的CFL球队？

Pick#	CFL team	Player	Position	College
-------	----------	--------	----------	---------

英文：How many CFL teams are from York University? ❌

How many CFL teams are from York College? ✔️

示例2:

中文：芝加哥的威利斯大厦有多少层？

Rank	Name	Location	Height(ft)	Floor
------	------	----------	------------	-------

英文：How many layers are there in the Willis Tower in Chicago? ❌

How many floors does the Willis Tower in Chicago have? ✔️

图 4-2 中文自然语言问题生成 SQL 查询语句的错误示例

Figure 4-2 An Error Example of Chinese Nature Language to SQL Statement

从图4-2中的示例一可以看出，数据库表模式中的列名为“College”，而谷歌翻译将中文“大学”翻译为“University”。而示例二中的“层”翻译为了“layers”而不是“floors”。形如这一类的问题会给 SQL 的生成带来很大的问题。

究其原因，从中文自然语言到英文自然语言再到 SQL 查询语句这一过程是一个紧密关联的过程，如果将其拆分为两个部分，则翻译的过程中将会丢失大量的数据库、SQL 语言本身的很多信息。所以，本文提出 TCR 模板用以将这两个独立的任务有机的统一起来，作为多任务学习网络的输入。

任务 (Task)	内容 (Content)	结果 (Result)
Please translate Chinese into English	告诉我南澳有哪些注意要点	Tell me what the notes are for South Australia
Please translate English into SQL statement	The table has column names... Tell me what the notes are for South Australia	SELECT notes from table WHERE 'Current Slogan' = 'South Australia'

图 4-3 TCR 示例

Figure 4-3 TCR Examples

如图4-3所示, 本文将中文自然语言翻译为英文自然语言任务和英文自然语言生成 SQL 查询语句任务使用 TCR 模板(任务-内容-结果)进行统一。例如, “告诉我南澳有哪些注意要点” 先翻译为英文, 其任务为 “Please translate Chinese into English”,

内容为 “告诉我南澳有哪些注意要点”(表明所需要翻译的中文语句), 结果为 “Tell me what the notes are for South Australia”。而后再将 “Tell me what the notes are for South Australia” 转换为 SQL 查询语句, 其任务为 “Please translate English into SQL statement”,

内容为 “The table has column names...Tell me what the notes are for South Australia”(表明数据库模式和英文查询语句), 结果为 “SELECT notes from table WHERE ‘Current Slogan’ = ‘South Australia’”, 从而完成生成的全过程。

TCR 模板将两个任务的模式进行了统一, 使得网络模型的输入和输出得以一致, 而不用设计两个不同的网络结构来处理这两个任务。在后文中, 本文还将这个模板用于自然语言处理领域中的多项任务中, 详见4.3节。

4.2.2 多任务学习网络

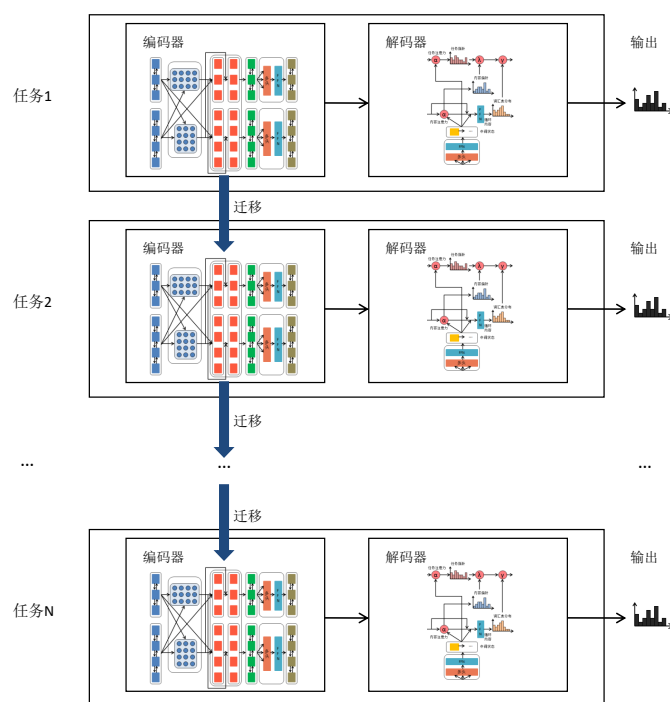


图 4-4 多任务学习网络的总体结构

Figure 4-4 Architecture of Multitasking Learning Network

本文使用 TCR 模板对每个任务进行统一并且在训练阶段采用联合训练的方法, 其

所使用的神经网络的结构称为多任务学习网络，如图4-5所示。近几年来，有不少研究者所研究的问答模型^[62-64]的和本文提出的模型较为类似，

他们的问答模型往往假设模型得到的答案片段可以直接从上下文信息中复制，但是本文提出的多任务学习网络适用于更复杂的问答场景。

在之前的 TCR 模板中，任务对应于问答模型中的问题，内容对应于问答模型中的上下文，而结果对应于问答模型中的回答。由于 TCR 模板中的任务往往包含限制搜索空间的非常关键的信息，本文会在多任务学习网络中使用了协同注意力机制^[33]并加以拓展，从而使得对模型输入的表示更加丰富。多任务学习网络还采用了指针机制^[65]，并将其改造为分层的多指针生成器，使得网络能够直接从任务和内容中进行文本的复制。

多任务网络的不同任务之间的迁移过程如图4-4所示，图中编码器和解码器为示意图，其详细结构见图4-5。可以看到，任务1训练完成时的对偶协同注意力中的参数可以被直接作为任务2对应参数的初始状态，这一过程也叫做微调（Fine tuning）。网络在其他任务上所学习到的一些表示可以通过这种方式进行迁移。在实验阶段，本文在多任务学习中还使用了不同的训练策略进行优化，详见4.3.2。

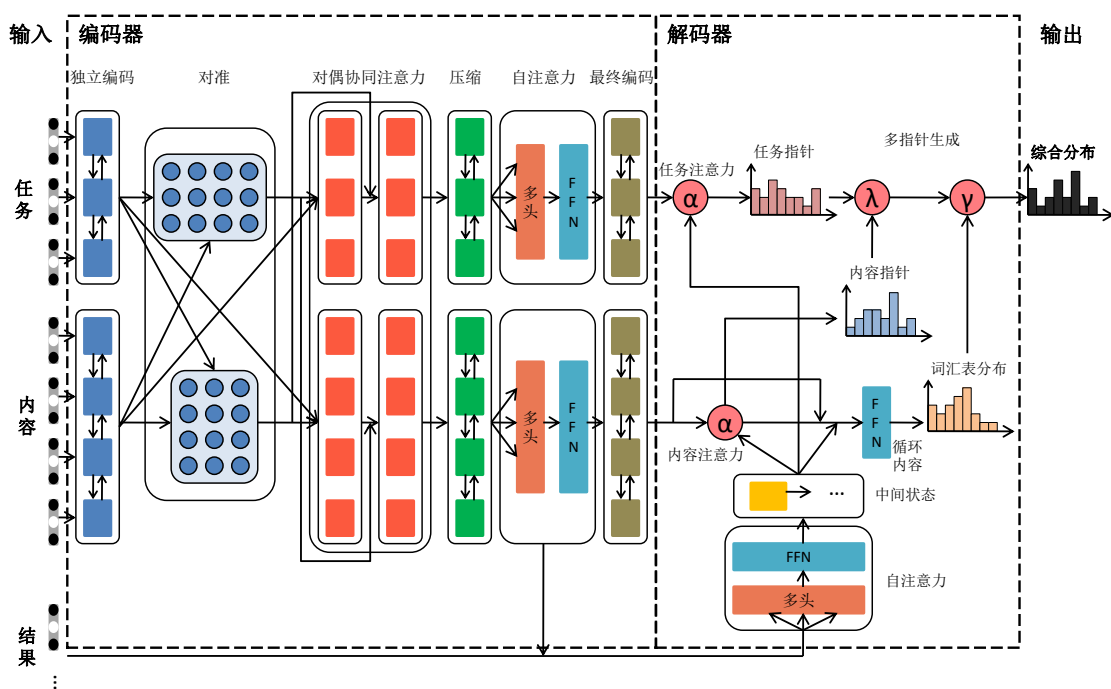


图 4-5 多任务学习网络的详细结构

Figure 4-5 Detail Structure of Multitasking Learning Network

在训练阶段，多任务学习网络的输入序列由三个部分组成，分别为：由 l 个单词构

成的内容 c ；由 m 个单词构成的任务 q ；由 n 个单词构成的结果 a 。其中，每个输入序列都是一个矩阵，矩阵中的第 i 行对应于序列中的第 i 个词的嵌入 (embedding) (可为字符向量或词向量)，维度为 d_{emb} 。有公式4-6：

$$C \in \mathbb{R}^{l \times d_{emb}} \quad Q \in \mathbb{R}^{m \times d_{emb}} \quad A \in \mathbb{R}^{n \times d_{emb}} \quad (4-6)$$

接下来，本文将分别详细阐述多任务学习网络中的编码器和解码器。

4.2.3 编码器

编码器将内容矩阵 C 、任务矩阵 Q 和结果矩阵 A 作为输入，使用深度栈式循环神经网络，结合协同注意力机制 (coattention) 和自注意力机制 (self-attention)，来生成编码阶段的最终的表示 $C_{fin} \in \mathbb{R}^{l \times d}$ 和 $Q_{fin} \in \mathbb{R}^{m \times d}$ (即编码之后的内容信息和任务信息)，并且还可以让网络学习到他们之间的局部和全局的相互依赖关系。编码器的工作流程由六个阶段组成：

(1) 独立编码阶段

首先使用一个简单的线性层将输入矩阵投射到 d 维的空间上，如公式4-7。

$$CW_1 = C_{proj} \in \mathbb{R}^{l \times d} \quad QW_1 = Q_{proj} \in \mathbb{R}^{m \times d} \quad (4-7)$$

这些投射之后的表示将被输入给一个共享的双向长短期记忆网络 (bi-LSTM)^[66, 67]，如公式4-8。

$$BILSTM_{ind}(C_{proj}) = C_{ind} \in \mathbb{R}^{l \times d} \quad BILSTM_{ind}(Q_{proj}) = Q_{ind} \in \mathbb{R}^{l \times d} \quad (4-8)$$

(2) 对准阶段

在获得协同注意力的表达之前，需要先对每个序列的编码表达进行对准。我分别给 C_{ind} 和 Q_{ind} 增加一个预训练的嵌入使得现在的 $C_{ind} \in \mathbb{R}^{(l+1) \times d}$ 以及 $Q_{ind} \in \mathbb{R}^{(m+1) \times d}$ ，这样做可以让每个单词不会和序列中的某个单词强制对准。

令 $\text{softmax}(X)$ 表示逐列进行 softmax 操作，即矩阵 X 中的每列进行标准化后的和为 1。本文将内容信息的序列表示与任务序列表示之间进行点积计算得到相似性得分，并使用归一化操作来获得数据的对准，如公式4-9：

$$\text{softmax}(C_{ind}Q_{ind}^T) = S_{cq} \in \mathbb{R}^{(l+1) \times (m+1)} \quad \text{softmax}(Q_{ind}C_{ind}^T) = S_{qc} \in \mathbb{R}^{(m+1) \times (l+1)} \quad (4-9)$$

(3) 对偶协同注意力阶段

再对准之后，要去计算一个序列中的某个单词和另一个序列中相关的单词的加权求和，如公式4-10。

$$S_{cq}^\top C_{ind} = C_{sum} \in \mathbb{R}^{(m+1) \times d} \quad S_{qc}^\top Q_{ind} = Q_{sum} \in \mathbb{R}^{(l+1) \times d} \quad (4-10)$$

对偶协同注意力就是要通过同样的权重将对准时得到的信息传递给原序列，如公式4-11。

$$S_{qc}^\top C_{sum} = C_{coa} \in \mathbb{R}^{(l+1) \times d} \quad S_{cq}^\top Q_{sum} = Q_{coa} \in \mathbb{R}^{(m+1) \times d} \quad (4-11)$$

可以发现，进行了加权求和和协同注意力的表示中的第一列为之前添加进去的冗余的嵌入。在这里不再需要这一个嵌入，所以将矩阵中的这一列去除掉，得到 $C_{coa} \in \mathbb{R}^{l \times d}$ 和 $Q_{coa} \in \mathbb{R}^{m \times d}$ 。

(4) 压缩阶段

为了将对偶协同注意力操作之前的信息压缩至 d 维，接着把之前得到的四种序列表示进行拼接并输入一个单独的双向 LSTM 中，如公式4-12。

$$BiLSTM_{comC}([C_{proj}; C_{ind}; Q_{sum}; C_{coa}]) = C_{com} \in \mathbb{R}^{m \times d} \quad (4-12)$$

$$BiLSTM_{comQ}([Q_{proj}; Q_{ind}; C_{sum}; Q_{coa}]) = Q_{com} \in \mathbb{R}^{m \times d} \quad (4-13)$$

(5) 自注意力阶段

接着，使用一个多头的放缩点积注意力机制 (multi-head, scaled dot-product attention)^[33] 来捕获每个序列内部的长距离的依赖性，其表达式为公式4-14。

$$Attention(\tilde{X}, \tilde{Y}, \tilde{Z}) = softmax\left\{\frac{\tilde{X}\tilde{Y}^\top}{\sqrt{d}}\right\}\tilde{Z} \quad (4-14)$$

$$MultiHead(\tilde{X}, \tilde{Y}, \tilde{Z}) = [h_1; \dots; h_p]W^o \quad \text{其中 } h_j = Attention(\tilde{X}W_j^{\tilde{X}}, \tilde{Y}W_j^{\tilde{Y}}, \tilde{Z}W_j^{\tilde{Z}}) \quad (4-15)$$

公式4-14中变换都为线性变换，所以多头注意力机制可以维持 d 维不变，有公式4-16：

$$MultiHead_C(C_{com}, C_{com}, C_{com}) = C_{mha} \quad MultiHead_Q(Q_{com}, Q_{com}, Q_{com}) = Q_{mha} \quad (4-16)$$

之后，本文使用了一个残差前馈网络 (feedforward networks, 简称 FFN) 如公式4-17，其中 $U \in \mathbb{R}^{d \times f}$, $V \in \mathbb{R}^{f \times d}$ 。其激活函数为 Relu 函数^[33, 68]，并且在输入和输出都使用了正则化 (layer normalization)^[69]。

$$FFN(X) = \max(0, XU)V + X \quad (4-17)$$

$$FFN_C(C_{com} + C_{mha}) = C_{self} \in \mathbb{R}^{l \times d} \quad FFN_Q(Q_{com} + Q_{mha}) = Q_{self} \in \mathbb{R}^{m \times d} \quad (4-18)$$

(6) 最终编码阶段

最后，使用两个双向 LSTM 将所有信息进行汇总并将矩阵 C_{fin} 和 Q_{fin} 输入给解码器，如公式4-19。

$$BiLSTM_{finC}(C_{self}) = C_{fin} \in \mathbb{R}^{l \times d} \quad BiLSTM_{finQ}(Q_{self}) = Q_{fin} \in \mathbb{R}^{m \times d} \quad (4-19)$$

4.2.4 解码器

在编码器得到最终的表示 $C_{fin} \in \mathbb{R}^{l \times d}$ 和 $Q_{fin} \in \mathbb{R}^{m \times d}$ （即编码之后的内容信息和任务信息）后进入到解码器解码。解码器的工作流程由四个阶段组成：

(1) 自注意力阶段

在训练阶段，解码器首先进行结果的表示，将结果 a 的表示投射到 d 维的空间上，如公式4-20

$$AW_2 = A_{proj} \in \mathbb{R}^{n \times d} \quad (4-20)$$

由于该过程不包含循环和卷积操作，所以为 A_{proj} 加上了一个位置编码信息 x ，如公式4-21。

$$A_{proj} + PE = A_{ppr} \in \mathbb{R}^{n \times d}, \quad \text{其中 } PE[t, k] = \begin{cases} \sin(\frac{t}{10000^{\frac{k}{2d}}}) & k \text{ 为偶数} \\ \cos(\frac{t}{10000^{\frac{k-1}{2d}}}) & k \text{ 为奇数} \end{cases} \quad (4-21)$$

接着使用自注意力机制^[33] 从而使得解码器能够知道之前的输出（若之前没有输出则认为之前的输出为某个初始化的单词）和相关内容是什么，从而产生下一个输出。该注意力层与编码器中的自注意力层相对应在多头的注意力机制之后使用了一个残差前馈网络（FFN，其定义在4.2.3节中的自注意力阶段给出），如公式4-22。

$$MultiHead_A(A_{ppr}, A_{ppr}, A_{ppr}) = A_{mha} \in \mathbb{R}^{n \times d} \quad (4-22)$$

$$MultiHead_AC((A_{mha} + A_{ppr}), C_{fin}, C_{fin}) = A_{ac} \in \mathbb{R}^{n \times d} \quad (4-23)$$

$$FFN_A(A_{ac} + A_{mha} + A_{ppr}) = A_{self} \in \mathbb{R}^{n \times d} \quad (4-24)$$

(2) 获得中间状态阶段

之后，使用一个标准的带注意力机制的 LSTM 网络来对每个时刻 t 产生一个内容状态 \tilde{c}_t 。这个 LSTM 又将使用之前的结果序列中的单词 A_{self}^{t-1} 和内容状态来生成一个中间状态 h_t ，如公式4-25。

$$LSTM([(A_{self})_{t-1}; \tilde{c}_{t-1}], h_{t-1}) = h_t \in \mathbb{R}^d \quad (4-25)$$

(3) 任务与内容注意力阶段

上一阶段中的中间状态可用来获得注意力权重 α_t^C 以及 α_t^Q ，解码器从而可以获得 t 时刻的编码信息，如公式4-26。

$$\text{softmax}(C_{fin}(W_2 h_t)) = \alpha_t^C \in \mathbb{R}^l \quad \text{softmax}(Q_{fin}(W_3 h_t)) = \alpha_t^Q \in \mathbb{R}^m \quad (4-26)$$

内容的表示将与这些权重相结合并输入给一个前馈网络从而形成内容状态与任务状态，激活函数为 \tanh ，如公式4-27。

$$\tanh(W_4[C_{fin}^\top \alpha_t^C; h_t]) = \tilde{c}_t \in \mathbb{R}^d \quad \tanh(W_5[Q_{fin}^\top \alpha_t^Q; h_t]) = \tilde{q}_t \in \mathbb{R}^d \quad (4-27)$$

(4) 多指针生成阶段

由于本文的模型必须要能够生成那些未出现在任务或内容序列中的单词，所以需要额外声明一个词汇表 v 。从任务、内容和外部的词汇表中分别获得每个单词的概率分布，如公式4-28。

$$\sum_{i:c_i=w_t} (\alpha_t^C)_i = p_c(w_t) \in \mathbb{R}^n \quad (4-28)$$

$$\sum_{i:q_i=w_t} (\alpha_t^Q)_i = p_q(w_t) \in \mathbb{R}^m \quad (4-29)$$

$$\text{softmax}(W_v \tilde{c}_t) = p_v(w_t) \in \mathbb{R}^v \quad (4-30)$$

这些概率分布将会覆盖任务、内容和外部词汇表中所有单词的集合，其中的一些条目将会被赋为 0 值从而使所有分布都在 \mathbb{R}^{l+m+v} 。最后，本文设置两个标量开关来调节每个分布的重要程度并确认最终输出的分布，如公式4-31。

$$\sigma(W_{pv}[\tilde{c}_t; h_t; (A_{self})_{t-1}]) = \gamma \in [0, 1] \quad (4-31)$$

$$\sigma(W_{cq}[\tilde{q}_t; h_t; (A_{self})_{t-1}]) = \lambda \in [0, 1] \quad (4-32)$$

$$\gamma p_v(w_t) + (1 - \gamma)[\lambda p_c(w_t) + (1 - \lambda)p_q(w_t)] = p(w_t) \in \mathbb{R}^{l+m+v} \quad (4-33)$$

需要说明的是，在训练的全时域中，本文采用的是单词级别的对数似然损失，如公式4-34。

$$\mathcal{L} = - \sum_t^T \log p(a_t) \quad (4-34)$$

4.3 实验与分析

4.3.1 多任务学习实验

表 4-1 多任务学习的实验结果

Table 4-1 The Experiment Result of Multitasking Learning

数据集	单任务				多任务				
	S2S	w/SAtt	+CAtt	+QPtr	S2S	w/SAtt	+CAtt	+QPtr	+ACurr
WikiSQL	60.0	72.4	72.3	72.6	45.8	64.8	72.9	74.0	78.7
IWSLT	25.0	23.3	26.0	25.5	14.2	23.6	29.0	26.1	29.7
SQuAD	48.2	68.2	74.6	75.5	47.5	66.8	71.8	70.8	74.3
CNN/DM	19.0	20.0	25.1	24.0	25.7	14.0	15.7	23.9	24.6
MNLI	67.5	68.5	34.7	72.8	60.9	69.0	70.4	70.5	69.2
SST	86.4	86.8	86.2	88.1	85.9	84.7	86.5	86.2	86.4
QA-SRL	63.5	67.8	74.8	75.2	68.7	75.1	76.1	75.8	77.6
QA-ZRE	20.0	19.9	16.6	15.6	28.5	31.7	28.5	28.0	34.7
WOZ	85.3	86.0	86.5	84.4	84.0	82.8	75.1	80.6	84.1
MWSC	43.9	46.3	40.4	52.4	52.4	43.9	37.8	48.8	48.4
总得分	-	-	-	-	483.6	566.4	543.8	584.7	607.7

本次实验中, 本文不仅将中英翻译任务 (IWSLT) 与 NL2SQL 任务 (WikiSQL) 进行同时学习, 而且还加入了阅读理解 (SQuAD)、摘要 (CNN/DM)、自然语言推理 (MNLI)、情绪识别 (SST)、语义角色标注 (QA-SRL)、关系抽取 (QA-ZRE)、对话系统 (WOZ)、语义解析 (MWSC) 任务进行多任务学习。需要说明的是, 每个任务的评价指标不一致, 例如: IWSLT 的指标为 BLEU, WikiSQL 的指标为逻辑形式准确率等等。

实验结果如表4-1所示, 表中 S2S 代表序列到序列 (sequence to sequence) 模型, (w/SAtt) 代表增加带自注意力机制的 S2S 模型, (+CAtt) 代表将任务与内容序列拆分为两个输入序列并增加对偶协同注意力机制, (+QPtr) 代表增加任务指针器, (+ACurr) 代表增加反递进学习过程。总得分表示多任务学习时各个子任务得分的和, 由于单任务不存在多任务的得分和所以标记为 ‘-’。模型的训练样本为包含任务序列、内容序列以及结果序列的三元组。本文所做的对比实验的基准为使用了指针生成器的序列到序列的模型 (简称 S2S 模型)^[70]。不一样的是, S2S 模型的输入为自然语言问题序列, 而多任务学习网络的输入为任务及内容序列的集合。

(1) 单任务模式下的实验结果

从表4-1中的数据可以看出, 在单任务的模式下, S2S 模型在 WikiSQL 数据集上的得分比之前的序列到序列的基准方案要高, 而多任务学习网络 (+QPtr) 的效果更加优异, 但 S2S 模型在 SQuAD 等任务上的效果较差。在 S2S 模型的基础上增加了带自注意力机制层 (w/SAAtt) 的编码器和解码器之后^[33], 模型具备了整合来自任务和内容信息的能力。从表中可以看出, 新的模型在 SQuAD 任务上提升了 20 nF1, QA-SRL 任务上提升了 4 nF1, WikiSQL 上提升了 12 LFEM。模型在 WikiSQL 上的表现接近了最高水平的范围, 在没有使用结构化的方法^[9, 29, 38] 下达到了 72.4%。

接着, 本文尝试将任务和内容从输入中进行拆分并增加了对偶协同注意力机制 (+CAAtt)。可以看到, 模型在 SQuAD 和 QA-SRL 上的性能提升了超过 5 nF1, 但是在其他任务上没有明显的提升, 甚至在 MNLI 和 MWSC 任务上的性能有所降低。其原因是由于两个任务往往能够从输入中直接复制一些单词作为输出, S2S 模型的输入为任务和内容信息的集合, 所以其中的指针生成器可以直接完成从输入中复制信息到输出的操作。而将任务和内容信息拆分为两个输入序列的时候, 模型就失去了这个能力。

为了解决这个问题, 本文在之前的模型上又增加了一个任务指针 (+QPtr) 进行实验。实验结果显示, 任务指针有效的提高了模型在 MNLI 和 MWSC 上的性能。同时, 模型在 SQuAD 任务上提升到了 75.5 nF1, 达到了 SQuAD 领域中使用直接跨度检测方法的水平, 也就是说多任务学习网络达到了不明确将问题进行跨度检测的方法中的最高水平。

最后的模型在 WikiSQL 任务上达到了 72.6% 的逻辑形式准确率以及 80.4% 的数据库执行准确率, 超过了之前的最高水平^[38] 的 71.7% 和 78.5%。

(2) 多任务模式下的实验结果

从表4-1中的数据可以看出, 在多任务的模式下, S2S 模型在很多任务下的表现相比于单任务模式还要更差, 模型的总得分只有 473.6 分。而增加了带自注意力机制层 (w/SAAtt)、对偶协同注意力机制 (+CAAtt)、任务指针 (+QPtr) 后模型的表现越来越好, 达到了 584.7 分。充分说明了模型在多任务场景下具有很好的通用性和可拓展性。多任务与单任务模型相比, 在 QA-ZRE 任务上的 F1 得分又有 11 点提升, 也验证了多任务的模型在解决零样本学习 (zero-shot learning) 上的能力。

更为重要的是, 在多任务模式下 WikiSQL 任务的逻辑形式准确率为 74.0%、数据库执行准确率为 83.4%, 使用反递进学习策略下的性能更加优秀, 达到 78.7% 和 86.1% 详见4.3.2节。

表 4-2 多任务学习网络在不同训练策略下的实验结果

Table 4-2 The Experimental Results of Multitasking Networks With Different Strategies

数据集	完全联合	递进	反递进		
			SQuAD	+IWSLT+CNN/DM	+MNLI
WikiSQL	62.0	68.6	78.7	54.8	42.6
IWSLT	16.1	4.3	29.7	18.7	19.0
SQuAD	70.8	43.4	74.3	74.5	74.6
CNN/DM	23.9	21.3	24.6	20.8	21.6
MNLI	70.5	58.9	69.2	69.6	72.7
SST	86.2	84.5	86.4	83.6	86.8
QA-SRL	75.8	70.6	77.6	77.5	75.1
QA-ZRE	28.0	24.6	34.7	30.1	37.7
WOZ	80.6	81.9	84.1	81.7	85.6
MWSC	48.8	41.5	48.4	34.9	41.5
总得分	562.7	499.6	607.7	546.2	557.2

4.3.2 优化策略实验

在多任务的训练过程中本文还进行了多种批量采样（batch-level sampling）策略的实验，包括联合训练、递进学习、反递进学习等，其实验结果如表4-2所示。

首先考虑的是完全联合（fully joint）的策略。从训练开始到结束，对所有的任务按照固定的顺序循环的进行批量采样。这种策略在迭代（iteration）次数较少的单任务下的表现良好，见表4-2，但在迭代次数较多的单任务下性能不佳。经过总结，本文发现单任务与多任务场景下的性能的差异与单任务的迭代次数之间有很强的关联。

由于上述原因，本文还尝试了一些反递进学习的策略^[71]。这些训练的策略都是由两阶段组成的：1）在第一阶段中对部分任务进行联合训练（往往选择较难的任务）。2）第二阶段根据完全联合策略进行对所有任务进行训练。

首先，尝试先将 SQuAD 任务进行单独训练，之后再对其他的所有任务进行完全联合训练。由于多任务学习网络对于所有任务来说是一种基于问答的方法，所以联想到是否可以先与训练 SQuAD 这样的 QA 数据集然后再对其他的类 QA 的任务进行训练。这种方法可以使得解码器先学会如何从内容信息中检索出有用信息，然后学习不同的任务以及如何产生属于不同任务领域的单词。在 SQuAD 这个任务场景下进行预训练已经被

证明可以提高 NLI 的性能^[49]。根据实验结果来看,这种方式相对于其他的训练策略而言是一种更有效的训练策略,在总得分上获得了 607.7 的最高分。需要特别提到的是,这种策略在 IWSLT 任务上的得分较低,但是在其他的任务中会有更大的提升,特别是使用指针的任务。

为了探索在递进学习策略的初始状态下增加额外的任务是否会进一步提高性能,本文还尝试了将 IWSLT、CNN/DM 任务和 IWSLT、CNN/DM、MNLI 任务加入到第一阶段进行训练。这些任务包含了与其他任务非常相关的训练样本,并且也包含了最长的结果序列。除此之外,这些任务具有很高的多样性,应该能够让解码器学会更多的解码方式,例如针对 IWSLT 的词汇表、针对 SQuAD 与 CNN/DM 的内容指针以及针对 MNLI 的任务指针。然而,实验结果表明这些新增的任务并没有提升模型的性能。在将 SQuAD, IWSLT, CNN/DM 和 MNLI 加入到递进学习的初始状态下时,其他的一些任务(例如 QA-SRL, WikiSQL 和 MWSC)的性能明显下降。

另外,本文也尝试了在递进学习策略的初始状态下使用了 SST, QA-SRL, QA-ZRE, WOZ, WikiSQL 和 MWSC,这也就意味着先选择一些最简单的任务并进行训练。实验证明,这个策略是一个非常低劣的策略,不仅在初始递进学习中的任务的性能很差,在 SQuAD 和 IWSLT 上的表现更差。

实验表明,对于 NL2SQL 任务而言,使用反递进学习策略的效果优于递进学习策略,也就是说明了先学习简易的任务未能使模型学到能应用于其他任务的表示,甚至使得模型想要学习到其他任务有用的内部表示变得更加地困难。除此之外,实验的结果也说明了多任务学习的挑战。通过改变所学习的任务的先后次序可能可以提高某些任务性能,但也很有可能使其他的任务的性能下降。这也是多任务学习中一个非常值得研究的问题。

4.3.3 实验分析




图 4-6 多任务学习网络输出来源

Figure 4-6 The Source of Multitasking Network Output

(1) 多指针生成器与任务识别

多任务学习网络会从三个方面进行选择：从词汇表生成词汇、任务序列上的指针以及内容序列上的指针。尽管模型没有明确的监督信号来训练这些选择，但网络仍可以学会如何在这三个选择之间进行切换。图4-6显示了本文最好的模型选择每个选项的频率是怎样的。可以看出，对于 SQuAD, QA-SRL 和 WikiSQL 任务，模型主要是从内容信息中进行选择和复制，这正是因为这些任务中的正确结果主要囊括在内容中。由于答案的摘要主要由内容中的单词组成，模型在 CNN/DM 任务中也是主要从内容中进行复制。对于 SST, MNLI 和 MWSC，由于任务序列中会包含需要的类别，所以模型也偏向选择任务指针。对于 IWSLT 和 WOZ，模型更喜欢选择从词汇表生成单词，因为中文的单词和对话的状态字段很少在对应的内容信息中。

同时，使用了 TCR 模板之后的所有任务之间不会使得模型产生混淆。例如：中文单词仅仅会在中文翻译成英文的过程中出现，而在情感分析任务中也从未输出过非“正面”或“负面”的情感类别。

(2) 模型的拓展性

多任务学习网络具有很好的拓展性，除了中文翻译为英文任务和英文生成 SQL 自然语言任务外对图4.3中的其他任务都有很好的表现。在这十个任务共同学习的模型的基础上进行其他任务的学习更加表现了模型良好的拓展性。对于两个新的任务，英文到捷克语的翻译任务以及命名实体识别（NER）上，使用训练好的模型进行微调可以在更少的迭代次数下达到模型的收敛，达到很好的效果。其中，英文到捷克语的翻译任务使用的是 En->Cs 数据集，NER 任务使用的是 OntoNotes 5.0 数据集^[72]。

(3) 文本分类的零样本学习

由于 MNLI 包含在是个任务中，因此模型也可以适应斯坦福自然语言推理语料库（SNLI）^[73]。在预训练的多任务学习网络之上进行微调可以达到 87% 的精确匹配分数，比随机初始化再训练提升了 2 分，也比现有的最高水平提升了 2 分^[74]。更值得注意的是，在没有对 SNLI 进行任何微调的情况下，在原模型上预训练的多任务学习网络仍然达到了 62% 的精确匹配分数。因为十个任务包含 SST 任务，所以它也可以在其他二元情感分类任务上表现良好。在亚马逊和 Yelp 评论数据集^[75]上，预训练的多任务学习网络分别达到了 82.1% 和 80.8% 的精确匹配分数并且不需要对模型进行任何微调。这些结果表明在多任务学习网络模型的基础上进行微调可以是的模型拓展到域外的问题上，甚至可以适应更广的文本分类问题上。

4.4 本章小结

为了进一步提高 NL2SQL 生成的准确性以及解决中文自然语言生成 SQL 查询语句的问题，本章提出了一种基于多任务学习的 NL2SQL 生成方法。本方法设计了 TCR 模

板，将中文自然语言转换为英文自然语言任务和英文自然语言转换为 SQL 查询语句任务进行统一。接着，提出了由编码器和解码器构成的多任务学习网络模型。其中，编码过程包含单独编码、对准、对偶协同注意力、压缩、自注意力和最终编码阶段；解码过程包含结果表示、自注意力、获得中间状态、任务与内容注意力、获得任务与内容状态、多指针生成阶段。最后，进行了多任务学习实验和优化策略实验。实验结果表明，本文方法能够很好地完成中文自然语言生成 SQL 语言任务，逻辑形式准确率和数据库执行准确率达到 78.7% 和 86.1%，同时还具有很好的可拓展性。

第五章 总结与展望

5.1 本文贡献

目前,数据库技术被广泛地应用于软件系统作为数据存储的主要方式。除了软件开发人员需要编程进行数据存取外,业务人员在 OLAP 和报表等应用场景中也需要编写 SQL 查询语句,从而实现灵活的数据按需读取。然而,掌握 SQL 语言需要使用者经过数据库和 SQL 相关知识的培训,且在使用时需要确切了解数据库的模式等信息。如果可以让使用者通过交互式的自然语言接口甚至直接使用自然语言来对数据库执行查询将大大缩短业务与技术的鸿沟,极大地提升软件的生产效率。在此背景下,本文对面向最终用户的 SQL 查询语句生成技术进行了研究,提出了基于映射的 INL2SQL 生成、基于深度强化学习的 NL2SQL 生成和基于多任务学习的 NL2SQL 生成三种方法。

本文的主要贡献和创新点包括:

1) 基于映射的交互式自然语言接口生成 SQL 查询语句的方法

本文提出了基于映射的交互式自然语言接口生成 SQL 语句的模型与方法,其核心思想是结合自然语言解析技术,使用人机交互的方式指导解析过程,通过依赖解析树生成、解析树节点映射、解析树优化重构、查询树翻译模块对用户输入的查询进行意图的解析并映射到 SQL 查询语句上。从 Classicmodels 和 MAS 数据集上的实验结果来看,模型在有交互的情况下在简单、中等、困难的场景下的表现为 100%、80%、35% 和 100%、93%、71%。通过交互式对话器和用户接口模块对意图解析和映射进行补充和重构,减少了自然语言解析中出现的歧义问题和错误情况,提升了 SQL 查询语句生成的有效性。

2) 基于深度强化学习的英文自然语言生成 SQL 查询语句的方法

本文提出了一种基于深度强化学习的 NL2SQL 生成的模型与方法。本方法在离线训练阶段,将 WikiSQL 中的数据进行序列表示后输入给网络模型,模型生成 SQL 查询语句后在数据库中执行,再使用奖励函数构造奖励用于强化网络模型。在在线生成阶段用户输入自然语言查询语句及数据库模式,训练好的网络模型将生成符合用户查询意图的 SQL 查询语句。本方法的网络模型,即增强解析器模型,由编码器和解码器构成,并结合了自注意力机制。通过引入强化学习技术,本方法将增强解析器学习的目标转换为策略的优化问题并对给出了解析器的状态和动作的定义。为了解决 SQL 查询语句中的过滤条件的顺序问题以及隐式列名的问题,还提出了非确定性预言和 ANYCOL 状态的解决办法。实验表明,与目前 NL2SQL 的现有方法相比,本方法在 WikiSQL 数据集上的表现一流,并且在 Spider 数据集的验证集和测试集上的表现超过同类方法,达到 23.2%

和 24.1%。

3) 中文自然语言生成 SQL 查询语句的方法

为了进一步提高 NL2SQL 生成的准确性以及解决中文自然语言生成 SQL 查询语句的问题, 本文提出了一种基于多任务学习的 NL2SQL 生成的模型与方法。本方法使用 TCR 模板把中文自然语言转换为英文自然语言任务和英文自然语言转换为 SQL 查询语句任务进行统一。再使用由编码器和解码器构成的多任务网络模型进行多任务学习。其中, 编码过程包含单独编码、对准、对偶协同注意力、压缩、自注意力和最终编码等阶段; 解码过程包含结果表示、自注意力、获得中间状态、任务与内容注意力、获得任务与内容状态、多指针生成等阶段。本文进行了多任务学习实验和优化策略实验, 在 WikiSQL 数据集上达到 72.4% 和 80.4% 的最高水平, 并且在引入更多的任务进行学习时达到了 607.7 的总分。实验表明, 本方法不仅能够提升英文自然语言生成 SQL 查询语句任务的准确性, 还能够很好地完成中文自然语言生成 SQL 语言任务, 同时还具有很好的可拓展性。

5.2 展望

由于时间和能力有限, 本文的研究工作还有不少不足, 我们计划在以下两个方面做进一步的研究和改进:

1) 交互式自然语言接口生成 SQL 查询语句的泛化能力

从本文的实验结果可以看出, 模型存在无法处理子查询、所需输入的自然语言意图形式较固定、无法处理特殊词组等问题, 需要进一步进行提升和改进。可以考虑使用深度学习进行语义分类、命名实体识别等手段辅助进行意图的提取。还可以采用将深度学习和模块化的工程相结合的方法, 提升系统对于子查询的处理能力。除此之外, 本文的交互方法较为简单, 接下来还可以考虑将任务型问答系统的相关技术(例如, 槽填充技术)运用在与用户的多轮交互中, 从而更好地解决歧义和信息缺失的问题。

2) 复杂 SQL 语句的自动生成

本文及其他最新的研究工作所使用到的数据集都是以 WikiSQL 数据集为主, 而 WikiSQL 数据属于 Spider 数据集中定义的简单和中等难度。本文提出的解决方案已经几乎达到简单和中等难度的 SQL 查询语句生成的最佳性能, 之后的模型需要更多地考虑解决语句的多样性和复杂性。可以通过分析困难和极难难度的 SQL 查询语句的特性来设计新的更复杂的神经网络结构, 可以考虑将深度学习和模块化的工程相结合的办法解决单个神经网络无法解决的问题。另外, SQL 查询语句只是 SQL 语句中结构最简单、语义最清楚的一种, 而范围更大的 SQL 语句的自动生成任务是更具挑战的。

参考文献

- [1] Androutsopoulos I, Ritchie G D, Thanisch P. Natural Language Interfaces to Databases - An Introduction[J]. Natural Language Engineering, 1995, 1(1): 29-81.
- [2] Woods W. The lunar sciences natural language information system[J]. BBN report, 1972.
- [3] Wallace M. Communicating with Databases in Natural Languages[J]., 1984.
- [4] Alshawhi H. The core language engine[M]. mit Press, 1992.
- [5] Goldman O, Latcinnik V, Naveh U, et al. Weakly-supervised Semantic Parsing with Abstract Examples[J]. ArXiv preprint arXiv:1711.05240, 2017.
- [6] Zhong V, Xiong C, Socher R. Seq2SQL: Generating structured queries from natural language using reinforcement learning[J]. ArXiv preprint arXiv:1709.00103, 2017.
- [7] Dong L, Lapata M. Language to logical form with neural attention[J]. ArXiv preprint arXiv:1601.01280, 2016.
- [8] Xu X, Liu C, Song D. Sqlnet: Generating structured queries from natural language without reinforcement learning[J]. ArXiv preprint arXiv:1711.04436, 2017.
- [9] Yu T, Li Z, Zhang Z, et al. TypeSQL: Knowledge-based Type-Aware Neural Text-to-SQL Generation[J]. ArXiv preprint arXiv:1804.09769, 2018.
- [10] Bhalotia G, Hulgeri A, Nakhe C, et al. Keyword searching and browsing in databases using BANKS[C] // Data Engineering, 2002. Proceedings. 18th International Conference on. 2002: 431-440.
- [11] Yu J X, Qin L, Chang L, et al. Keyword Search in Databases (Synthesis Lectures on Data Management)[J]., 2010.
- [12] Agrawal S, Chaudhuri S, Das G. DBXplorer: A system for keyword-based search over relational databases[C] // Data Engineering, 2002. Proceedings. 18th International Conference on. 2002: 5-16.
- [13] Hristidis V, Papakonstantinou Y. Discover: Keyword search in relational databases[C] // VLDB'02: Proceedings of the 28th International Conference on Very Large Databases. 2002: 670-681.

- [14] Tata S, Lohman G M. SQAK: doing more with keywords[C]// Proceedings of the 2008 ACM SIGMOD international conference on Management of data. 2008: 889-902.
- [15] Simitsis A, Koutrika G, Ioannidis Y. Précis: from unstructured keywords as queries to structured databases as answers[J]. The VLDB Journal—The International Journal on Very Large Data Bases, 2008, 17(1): 117-149.
- [16] Ganti V, He Y, Xin D. Keyword++: A framework to improve keyword search over entity databases[J]. Proceedings of the VLDB Endowment, 2010, 3(1-2): 711-722.
- [17] Blunschi L, Jossen C, Kossmann D, et al. Soda: Generating sql for business users[J]. Proceedings of the VLDB Endowment, 2012, 5(10): 932-943.
- [18] Bergamaschi S, Guerra F, Interlandi M, et al. QUEST: a keyword search system for relational data based on semantic and machine learning techniques[J]. Proceedings of the VLDB Endowment, 2013, 6(12): 1222-1225.
- [19] Popescu A M, Etzioni O, Kautz H. Towards a theory of natural language interfaces to databases[C]// Proceedings of the 8th international conference on Intelligent user interfaces. 2003: 149-157.
- [20] Popescu A M, Armanasu A, Etzioni O, et al. Modern natural language interfaces to databases: Composing statistical parsing with semantic tractability[C]// Proceedings of the 20th international conference on Computational Linguistics. 2004: 141.
- [21] Kuepper D, Storbel M, Roesner D. NAUDA: A cooperative natural language interface to relational databases[J]. ACM SIGMOD Record, 1993, 22(2): 529-533.
- [22] Li Y, Yang H, Jagadish H. NaLIX: an interactive natural language interface for querying XML[C]// Proceedings of the 2005 ACM SIGMOD international conference on Management of data. 2005: 900-902.
- [23] De Marneffe M C, MacCartney B, Manning C D. Generating typed dependency parses from phrase structure parses[J]., 2018.
- [24] Wu Z, Palmer M. Verb semantics and lexical selection In Proceedings of the 32nd annual meeting of the association for computational linguistics[J]. New Mexico, 1994.
- [25] Xiao C, Wang W, Lin X, et al. Efficient similarity joins for near-duplicate detection[J]. ACM Transactions on Database Systems (TODS), 2011, 36(3): 15.
- [26] Li F, Jagadish H. Constructing an interactive natural language interface for relational databases[J]. Proceedings of the VLDB Endowment, 2014, 8(1): 73-84.

- [27] Zeng Y, Bao Z, Ling T W, et al. Breaking out of the mismatch trap[C]// Data Engineering (ICDE), 2014 IEEE 30th International Conference on. 2014: 940-951.
- [28] Wang C, Brockschmidt M, Singh R. Pointing Out SQL Queries From Text[J]., 2018.
- [29] Huang P S, Wang C, Singh R, et al. Natural Language to Structured Query Generation via Meta-Learning[J]. ArXiv preprint arXiv:1803.02400, 2018.
- [30] Wang C, Huang P S, Polozov A, et al. Execution-guided neural program decoding[J]. ArXiv preprint arXiv:1807.03100, 2018.
- [31] Goodfellow I, Bengio Y, Courville A, et al. Deep learning[M]. Vol. 1. MIT press Cambridge, 2016.
- [32] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323(6088): 533.
- [33] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]// Advances in Neural Information Processing Systems. 2017: 5998-6008.
- [34] Price P J. Evaluation of spoken language systems: The ATIS domain[C]// Speech and Natural Language: Proceedings of a Workshop Held at Hidden Valley, Pennsylvania, June 24-27, 1990. 1990.
- [35] Dahl D A, Bates M, Brown M, et al. Expanding the scope of the ATIS task: The ATIS-3 corpus[C]// The Workshop on Human Language Technology. 1994: 43-48.
- [36] Zelle J M, Mooney R J. Learning to parse database queries using inductive logic programming[C]// Thirteenth National Conference on Artificial Intelligence. 2008.
- [37] Yu T, Zhang R, Yang K, et al. Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task[C]// Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 3911-3921.
- [38] Dong L, Lapata M. Coarse-to-Fine Decoding for Neural Semantic Parsing[J]. ArXiv preprint arXiv:1805.04793, 2018.
- [39] Pennington J, Socher R, Manning C. Glove: Global vectors for word representation[C]// Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014: 1532-1543.

- [40] Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. ArXiv preprint arXiv:1412.6980, 2014.
- [41] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. ArXiv preprint arXiv:1301.3781, 2013.
- [42] Kiros R, Zhu Y, Salakhutdinov R, et al. Skip-thought vectors[C]// Proceedings of the 28th International Conference on Neural Information Processing Systems-Volume 2. 2015: 3294-3302.
- [43] Collobert R, Weston J. A unified architecture for natural language processing: Deep neural networks with multitask learning[C]// Proceedings of the 25th international conference on Machine learning. 2008: 160-167.
- [44] Collobert R, Weston J, Bottou L, et al. Natural language processing (almost) from scratch[J]. Journal of Machine Learning Research, 2011, 12(Aug): 2493-2537.
- [45] Peters M E, Neumann M, Iyyer M, et al. Deep contextualized word representations[J]. ArXiv preprint arXiv:1802.05365, 2018.
- [46] Ramachandran P, Liu P, Le Q. Unsupervised Pretraining for Sequence to Sequence Learning[C]// Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 383-391.
- [47] Howard J, Ruder S. Fine-tuned Language Models for Text Classification[J]. ArXiv preprint arXiv:1801.06146, 2018.
- [48] McCann B, Bradbury J, Xiong C, et al. Learned in translation: Contextualized word vectors[C]// Advances in Neural Information Processing Systems. 2017: 6294-6305.
- [49] Min S, Seo M, Hajishirzi H. Question answering through transfer learning from large fine-grained supervision data[J]. ArXiv preprint arXiv:1702.02171, 2017.
- [50] Zoph B, Yuret D, May J, et al. Transfer Learning for Low-Resource Neural Machine Translation[C]// Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. 2016: 1568-1575.
- [51] Hashimoto K, Tsuruoka Y, Socher R, et al. A Joint Many-Task Model: Growing a Neural Network for Multiple NLP Tasks[C]// Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 1923-1933.

- [52] Johnson M, Schuster M, Le Q V, et al. Google's Multilingual Neural Machine Translation System: Enabling Zero-Shot Translation[J]. Transactions of the Association of Computational Linguistics, 2017, 5(1): 339-351.
- [53] Luong M T, Le Q V, Sutskever I, et al. Multi-task sequence to sequence learning[J]. ArXiv preprint arXiv:1511.06114, 2015.
- [54] Kaiser L, Gomez A N, Shazeer N, et al. One model to learn them all[J]. ArXiv preprint arXiv:1706.05137, 2017.
- [55] Xiong C, Merity S, Socher R. Dynamic memory networks for visual and textual question answering[C]// International conference on machine learning. 2016: 2397-2406.
- [56] Ruder S, Bingel J, Augenstein I, et al. Learning what to share between loosely related tasks[J]. ArXiv preprint arXiv:1705.08142, 2017.
- [57] Caruana R. Multitask learning[J]. Machine learning, 1997, 28(1): 41-75.
- [58] Mitchell T M. The need for biases in learning generalizations[M]. Department of Computer Science, Laboratory for Computer Science Research, Rutgers Univ. New Jersey, 1980.
- [59] Wang A, Singh A, Michael J, et al. GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding[J]. ArXiv preprint arXiv:1804.07461, 2018.
- [60] Poliakov A, Belinkov Y, Glass J, et al. On the Evaluation of Semantic Phenomena in Neural Machine Translation Using Natural Language Inference[J]. ArXiv preprint arXiv:1804.09779, 2018.
- [61] Poliakov A, Haldar A, Rudinger R, et al. Towards a Unified Natural Language Inference Framework to Evaluate Sentence Representations[J]. ArXiv preprint arXiv:1804.08207, 2018.
- [62] Wang S, Jiang J. Machine comprehension using match-lstm and answer pointer[J]. ArXiv preprint arXiv:1608.07905, 2016.
- [63] Seo M, Kembhavi A, Farhadi A, et al. Bidirectional attention flow for machine comprehension[J]. ArXiv preprint arXiv:1611.01603, 2016.
- [64] Xiong C, Zhong V, Socher R. Dcn+: Mixed objective and deep residual coattention for question answering[J]. ArXiv preprint arXiv:1711.00106, 2017.

- [65] Vinyals O, Fortunato M, Jaitly N. Pointer networks[C] // Advances in Neural Information Processing Systems. 2015: 2692-2700.
- [66] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [67] Graves A, Schmidhuber J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures[J]. Neural Networks, 2005, 18(5-6): 602-610.
- [68] Nair V, Hinton G E. Rectified Linear Units Improve Restricted Boltzmann Machines[C] // International Conference on International Conference on Machine Learning. 2010: 807-814.
- [69] Ba J L, Kiros J R, Hinton G E. Layer Normalization[J]., 2016.
- [70] See A, Liu P J, Manning C D. Get To The Point: Summarization with Pointer-Generator Networks[J]., 2017: 1073-1083.
- [71] Bengio Y, Louradour J, Collobert R, et al. Curriculum learning[J]. Proc.int.conf.on Machine Learning, 2009, 60(60): 6.
- [72] Hovy E, Marcus M, Palmer M, et al. OntoNotes: the 90% solution[C] // Human Language Technology Conference of the North American Chapter of the Association of Computational Linguistics. 2006.
- [73] Bowman S R, Angeli G, Potts C, et al. A large annotated corpus for learning natural language inference[J]. Computer Science, 2015.
- [74] Kim S, Hong J H, Kang I, et al. Semantic Sentence Matching with Densely-connected Recurrent and Co-attentive Information[J]., 2018.
- [75] Kotzias D, Denil M, Freitas N D, et al. From Group to Individual Labels Using Deep Features[C] // Acm Sigkdd International Conference on Knowledge Discovery & Data Mining. 2015.

致 谢

一转眼，我的研究生生涯即将结束了，回想自己在交大的这两年半的时光，感触良多。在此我要向研究生期间给予过我指导的所有老师、陪伴我成长的各位同学致以诚挚的感谢。

首先，我要对我的研究生导师沈备军老师表示感谢。在科研方面，沈老师一直鼓励和尊重我选择自己感兴趣的研究方向，引导并指导我的研究内容，沈老师认真严谨的办事作风和勤勤恳恳的工作态度给我留下了深刻的印象。在工程开发上，沈老师让我积极地参与和主导实验室的项目，使我积累了一定的项目经验并提高了技术水平。在生活中，沈老师也非常关心我的身体健康，主动为我排忧解难。此外，沈老师资助我前往美国参加国际会议，让我开阔了视野并结识了许多优秀的同行。

还要感谢研究生期间所有的老师，他们孜孜不倦的教诲使我丰富了知识，细致入微的工作使我们可以顺利并愉快地度过这两年半的时光。感谢莫文凯和陈凯学长，在我做研究实验与发表论文时都给予我很大的帮助，为我树立了榜样。感谢黄卫智、杨宇、李宁和董翔学长，不仅在项目开发上为我解答释疑，在毕业之后还与我分享工作心得与感悟，让我不断成长。感谢实验室的所有同学，我们一起做项目、一起讨论技术难题、一起团队建设，大家的陪伴与支持让我能够一路前行。

最后，我要感谢我的父母和女友，和你们在一起是我最轻松和快乐的时候。无论我是否努力，是否优秀，不管我做怎样的决定，你们都一直在我的身后坚定地支持我。

攻读学位期间发表的学术论文

- [1] XIONG Y, MENG Z, SHEN B, et al. Mining Developer Behavior Across GitHub and StackOverflow. The 29th International Journal of Software Engineering and Knowledge Engineering, PP.578-583, Pittsburgh, USA, July 5th-7th, 2017.
- [2] XIONG Y, MENG Z, SHEN B, et al. Developer Identity Linkage and Behavior Mining Across GitHub and StackOverflow. International Journal of Software Engineering and Knowledge Engineering, 2018, Volume 27 No.9 & 10: 1409-1425 [SCI 检索] WOS: 000423457100004.